

数理统计

袁浩然 2233210080

1 统计量及其分布

第一章主要涉及了这些内容，首先在总体与样本的概念基础之上，我们介绍了统计量的概念，这是我们进行后面讨论的基础。在统计中，我们经常会讨论平均值的分布，这里的分布分为了精确分布与近似分布，精确分布一般依赖于分布的特殊性，包括可加性、特征函数的再生性等，而近似分布一般采用中心极限定理的思路解决。此外，由于中心极限定理的特殊性，我们可以利用依概率收敛的概念解决检验次数的问题。此外，对样本相关的统计量我们主要讨论了均值、方差、样本矩、偏度、峰度以及顺序统计量的具体含义与性质。此后我们介绍了三大抽样分布，这三个抽样分布帮助我们在后续的区间估计与正态检测中提供了必要的统计量：卡方分布帮助我们利用 s^2 与 σ^2 的关系， F 分布帮助我们建立两组样本的 s^2 与 σ^2 的关系， t 分布帮助我们建立了 μ 与 $s, \bar{x}$ 的关系。最后介绍了充分统计量的概念，为后续寻找 $UMVUE$ 提供了便利。

1.1 总体与样本

这里我们只需要把高中时候所学的知识复习一下就可以了，所谓总体就是研究对象的群体，构成总体的每个成员称为一个个体，总体可以分为有限总体和无限总体。

另外，我们可以通过抽样的形式对总体的情况进行估计，这里主要讲到了两种样本：完全样本和分组样本，其中完全样本中样本观测值有具体的数值，而分组样本中观测值知识一个范围。

我们最常用的抽样方法就是简单随机抽样，其需要满足两个要求：

1. 样本具有代表性，要求每一个个体都有同等机会被选入样本，这意味着每个样本 x_i 与总体 X 有相同的分布。
2. 样本要有独立性，要求样本中每一样品的取值不影响其他样品的取值，这意味着 $x_1, x_2, \dots, x_n$ 相互独立。

设总体 X 具有分布函数 $F(x)$, $x_1, x_2, \dots, x_n$ 为取自该总体的容量为 n 的样本，则样本的联合分布函数为

$$F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$$

例 1.1.1. 设有一批产品共 N 个, 需要进行抽样检验以了解其不合格品率 p , 先从中取出 n 个注意检查他们是否是不合格品, 如果把合格品记为 0, 不合格品记为 1, 分析总体量很大或不大时这是不是一个简单随机抽样。

1.2 样本数据的整理与显示

这里我们首先介绍一下经验分布函数。

定义 1.2.1. 设 $x_1, x_2, \dots, x_n$, 是取自总体分布函数为 $F(x)$ 的样本, 若将样本观测值由小到大进行排列, 记为 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$, 则 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ 称为有序样本, 用有序样本定义如下函数

$$F_n(x) = \begin{cases} 0, & \text{当 } x < x_{(1)}, \\ k/n, & \text{当 } x_{(k)} \leq x < x_{(k+1)}, \quad k = 1, 2, \dots, n-1, \\ 1, & \text{当 } x \geq x_{(n)} \end{cases}$$

则称 $F_n(x)$ 是该样本的经验分布函数。

他有这样的性质:

定理 1.2.1. 令 $F_n(x)$ 表示来自总体 $F(\cdot)$ 样本量为 n 的随机样本的样本累积分布函数, 则

$$P(F_n(x)) = \binom{n}{k} [F(x)]^k [1 - F(x)]^{n-k}, \quad k = 0, 1, \dots, n$$

1.3 统计量及其分布

我们在这一部分将会研究样本均值方差等内容, 这些概念都是属于统计量, 首先我们介绍一下统计量的概念。

定义 1.3.1. 设 $x_1, x_2, \dots, x_n$ 为取自某总体的样本, 若样本函数 $T = T(x_1, x_2, \dots, x_n)$ 中不含有任何未知参数, 则称 T 为统计量, 统计量的分布称为抽样分布。

从上面我们不难发现, 样本均值和方差都是统计量, 且样本均值满足如下两个性质:

性质 1.3.1. 样本中的数据与样本均值之差称为偏差, 样本中所有偏差之和等于 0。

性质 1.3.2. 数据观测值与样本均值的偏差平方和最小。

在这里我们讨论一下几个常见分布的样本均值的精确分布的问题, 我们一般有这样的方法求解:

1. 直接利用随机变量的可加性, 得到结果:

例 1.3.1. 令 $X_1, \dots, X_n$ 是来自 *Bernoulli* 分布的样本, 求出 $\bar{X}_n$ 的精确分布。

例 1.3.2. 令 $X_1, \dots, X_n$ 是来自泊松分布 $P(\lambda)$ 的样本, 求出 $\bar{X}_n$ 的精确分布。

例 1.3.3. 令 $X_1, \dots, X_n$ 是来自正态分布 $\mathcal{N}(\mu, \sigma^2)$ 的样本, 求出 $\bar{X}_n$ 的精确分布。

2. 利用伽马分布的特殊性求解。

例 1.3.4. 令 $X_1, \dots, X_n$ 是来自指数分布 $\exp(\theta)$ 的随机样本, 求 $\bar{X}_n$ 的精确分布

这里我们回顾一下:

$$\sum_{i=1}^n X_i \sim \text{Ga}(n, \theta)$$

因此这个问题就很好解决了。这里我们要注意从 $\sum_{i=1}^n X_i$ 变换到 $\bar{X}_n$ 我们应当做好概率密度函数的变换。

3. 利用特征函数求解: 我们有这样的定理:

定理 1.3.1. 对于独立同分布的随机变量 $X_1, X_2, \dots, X_n$, 他们的和 $\sum_{i=1}^n X_i$ 的特征函数等于各随机变量特征函数的乘积, 即:

$$\mathbf{E}\left(\exp\left\{it \sum_{j=1}^n X_j\right\}\right) = \prod_{j=1}^n \mathbf{E}(e^{itX_j})$$

所以结合这样的性质, 我们来讨论这样的例题:

例 1.3.5. 令 $X_1, \dots, X_n$ 是来自柯西分布 $\text{Cauchy}(a, b)$ 的随机样本, 求 $\bar{X}_n$ 的精确分布

这里我们的处理方式求解函数的特征函数

$$\mathbf{E}(e^{itX}) = e^{ita - b|t|}$$

对于一个总体, 我们对其进行抽样, 并求出样本的均值, 这时我们发现, 样本均值 $\bar{x}$ 大致服从一个高斯分布, 其理论依据如下:

定理 1.3.2. 设 $x_1, x_2, \dots, x_n$ 是来自某个总体的样本, $\bar{x}$ 为样本均值。

1. 若总体分布为 $\mathcal{N}(\mu, \sigma^2)$, 则 $\bar{x}$ 的精确分布为 $\mathcal{N}(\mu, \sigma^2/n)$ 。
2. 若总体分布未知或不是正态分布, $\mathbf{E}(x) = \mu$, $\mathbf{Var}(x) = \sigma^2$ 存在, 则 n 较大时 $\bar{x}$ 的渐近分布为 $\mathcal{N}(\mu, \sigma^2/n)$, 常记为 $\bar{x} \sim \mathcal{N}(\mu, \sigma^2/n)$, 这里渐近分布是指 n 较大时的近似分布。

这里给出使用弱大数定律求解近似值问题的方法:

定理 1.3.3. 假设密度函数 $f(\cdot)$ 的均值和方差分别为 μ 和 $\sigma^2 < +\infty$, 令 $\bar{X}_n$ 是来自 $f(\cdot)$ 的样本量为 n 的随机样本的样本均值。令 ε 和 δ 是任意两个满足 $\varepsilon > 0$ 和 $0 < \delta < 1$ 的正数, 如果 n 是大于 $\sigma^2/(\delta\varepsilon^2)$ 的正整数, 则

$$P(|\bar{X}_n - \mu| < \varepsilon) \geq 1 - \delta$$

例 1.3.6. 假设某一分布的均值未知, 方差为 1, 则为了使得样本均值 $\bar{X}_n$ 和总体均值 μ 的差异以至少 0.95 的概率在 0.5 之内, 则至少需要多少样本?

下面我们来研究样本方差, 这个概念我们是非常熟悉的, 但是在这里我们补充一点: 当 n 不大时, 常用

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

作为样本方差 (无偏方差), 这里我们解释一下为什么是 $n-1$: 根据上面的性质 1, 我们有 s_n^2 中的偏差平方和中的 n 项中有 $n-1$ 项是“随意变动”的, 而剩下的一项“由其他项确定”, 所以这里的 $n-1$ 也被称为自由度。

定理 1.3.4. 令 $X_1, \dots, X_n$ 是来自总体的随机样本, 令

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

则

$$\mathbf{E}(S^2) = \sigma^2, \quad \mathbf{Var}(S^2) = \frac{1}{n} \left(\mu_4 - \frac{n-3}{n-1} \sigma^4 \right)$$

其中 μ_4 是总体的四阶矩。

样本作为总体的表现, 其均值和方差与总体的期望和方差关系巨大:

定理 1.3.5. 设总体 X 有二阶矩, 即 $\mathbf{E}(X) = \mu$, $\mathbf{Var}(X) = \sigma^2 < \infty$, $x_1, x_2, \dots, x_n$ 为从该总体得到的样本, $\bar{x}$ 和 s^2 分别是样本均值和样本方差, 则

$$\mathbf{E}(\bar{x}) = \mu, \quad \mathbf{Var}(\bar{x}) = \sigma^2/n, \quad \mathbf{E}(s^2) = \sigma^2$$

与随机变量相同, 样本也同样有矩的概念:

定义 1.3.2. 设 $x_1, x_2, \dots, x_n$ 是样本, k 为正整数, 则统计量

$$a_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$

称为样本 k 阶原点矩, 统计量

$$b_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k$$

称为样本 k 阶中心矩。

为了衡量样本数据的对称性，我们有样本偏度的概念：

定义 1.3.3. 设 $x_1, x_2, \dots, x_n$ 为样本，称统计量

$$\hat{\beta}_s = b_3/b_2^{\frac{3}{2}}$$

为样本偏度。

当样本偏度大于零，样本的右尾长，当样本偏度小于零，样本左尾长。

另外一个相像的概念是峰度：

定义 1.3.4. 设 $x_1, x_2, \dots, x_n$ 为样本，则称统计量

$$\hat{\beta}_k = \frac{b_4}{b_2^2} - 3$$

为样本峰度。

还有一个是样本变异系数：

定义 1.3.5. 设 $X_1, \dots, X_n$ 是来自 X 的随机样本， $\bar{X}_n$ 是样本均值且不等于零， S_n 是样本标准差，则称统计量

$$\hat{v} = \frac{S_n}{\bar{X}_n}$$

为样本变异系数

在前面一节讲解经验分布函数的时候，我们对样本的大小进行了排列，这种方式我们称之为次序统计量。每个次序统计量 $x_{(k)}$ 的分布都具有一定的特点，首先介绍单个次序统计量的分布：

定理 1.3.6. 设总体 X 的密度函数为 $p(x)$ ，分布函数为 $F(x)$ ， $x_1, x_2, \dots, x_n$ 为样本，则第 k 个次序统计量 $x_{(k)}$ 的密度函数为

$$p_k(x) = \frac{n!}{(k-1)!(n-k)!} (F(x))^{k-1} (1-F(x))^{n-k} p(x)$$

例 1.3.7. 设总体密度函数为

$$p(x) = 3x^2, \quad 0 < x < 1$$

现从该总体抽得一个容量为 5 的样本，试计算 $P(x_{(2)} < 1/2)$ 。

我们将上面的结论推广到 2 维，就有了这样的结论：

定理 1.3.7. 次序统计量 $(x_{(i)}, x_{(j)})$ ($i < j$) 的联合分布密度函数为

$$p_{ij}(y, z) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} [F(y)]^{i-1} [F(z) - F(y)]^{j-i-1} [1 - F(z)]^{n-j} p(y)p(z), \quad y \leq z$$

1.4 三大抽样分布

在本节中,我们将关注由正态分布为基础产生的三种重要的抽样分布。

表 5.4.1 三个著名统计量的构造及其抽样分布

统计量的构造	抽样分布密度函数	期望	方差
$\chi^2 = x_1^2 + x_2^2 + \cdots + x_n^2$	$p(y) = \frac{1}{\Gamma\left(\frac{n}{2}\right) 2^{n/2}} y^{\frac{n}{2}-1} e^{-\frac{y}{2}} \quad (y>0)$	n	$2n$
$F = \frac{(y_1^2 + y_2^2 + \cdots + y_m^2)/m}{(x_1^2 + x_2^2 + \cdots + x_n^2)/n}$	$p(y) = \frac{\Gamma\left(\frac{m+n}{2}\right) \left(\frac{m}{n}\right)^{m/2}}{\Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right)} y^{\frac{m}{2}-1} \left(1 + \frac{m}{n}y\right)^{-\frac{m+n}{2}} \quad (y>0)$	$\frac{n}{n-2}$ ($n>2$)	$\frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}$ ($n>4$)
$t = \frac{y_1}{\sqrt{(x_1^2 + x_2^2 + \cdots + x_n^2)/n}}$	$p(y) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi} \Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{y^2}{n}\right)^{-\frac{n+1}{2}} \quad (-\infty < y < \infty)$	0 ($n>1$)	$\frac{n}{n-2}$ ($n>2$)

1.4.1 χ^2 分布

χ^2 分布是样本的平方和, 它的定义是这样的:

定义 1.4.1. 设 $X_1, X_2, \cdots, X_n$ 独立同分布于标准正态分布 $\mathcal{N}(0, 1)$, 则 $\chi^2 = X_1^2 + X_2^2 + \cdots + X_n^2$ 的分布称为自由度为 n 的 χ^2 分布, 记为 $\chi^2 \sim \chi^2(n)$. 其概率密度函数为

$$p(y) = \frac{(1/2)^{\frac{n}{2}}}{\Gamma(n/2)} y^{\frac{n}{2}-1} e^{-\frac{y}{2}}$$

另外, 它的期望与方差满足: $E(\chi^2) = n$, $Var(\chi^2) = 2n$ 他的特征函数为

$$\psi_X(t) = (1 - 2it)^{-\frac{k}{2}}$$

此外, 如果我们设 $X \sim \chi^2(k_1)$, $Y \sim \chi^2(k_2)$, 且 X 与 Y 独立, 则 $X + Y \sim \chi^2(k_1 + k_2)$.

例 1.4.1. 设 $x_1, x_2, \cdots, x_n$ 是来自正态分布 $\mathcal{N}(\mu, \sigma^2)$ 的一个样本, 其中 μ 是已知常数, 求统计量

$$T = \sum_{i=1}^n (x_i - \mu)^2$$

的分布

这里我们建立正态分布与 χ^2 分布的关系:

定理 1.4.1. 如果随机变量 $Z_1, \cdots, Z_n$ 独立同分布于标准正态分布 $\mathcal{N}(0, 1)$, 则 $Z = \sum_{j=1}^k Z_j^2$ 服从自由度为 k 的 χ^2 分布。

对于一般的正态分布，我们是这样定义的：

推论 1.4.1. 如果随机变量 $X_1, \dots, X_n$ 相互独立，且 $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$, $i = 1, \dots, k$ ，则

$$\sum_{i=1}^k \left(\frac{X_i - \mu_i}{\sigma_i} \right)^2$$

服从自由度为 k 的 χ^2 分布

推论 1.4.2. 如果 $X_1, \dots, X_n$ 是来自正态总体 $\mathcal{N}(\mu, \sigma^2)$ 的随机样本，则

$$\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2$$

服从自由度为 n 的 χ^2 分布。

下面是关于 χ^2 分布最为重要的结论：

定理 1.4.2. 设 $x_1, x_2, \dots, x_n$ 是来自正态总体 $\mathcal{N}(\mu, \sigma^2)$ 的样本，其样本均值和样本方差为

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \text{ 和 } s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

则有

1. $\bar{x}$ 与 s^2 相互独立
2. $\bar{x} \sim \mathcal{N}(\mu, \sigma^2/n)$
3. $\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$

这里，我们建立了 s^2 与 σ^2 的关系，这里为我们后续学习区间估计和正态检验提供了便利，如果在检验与估计时我们不知道 μ 的值，则我们可以利用 $\frac{(n-1)s^2}{\sigma^2}$ 估计。

最后，由于 χ^2 分布的常见性，我们介绍一下它的数值结果的计算方法：当随机变量 $\chi^2 \sim \chi^2(n)$ 时，对给定 α ($0 < \alpha < 1$)，称满足概率等式 $P(\chi^2 \leq \chi_{1-\alpha}^2(n)) = 1 - \alpha$ 的 $\chi_{1-\alpha}^2(n)$ 是自由度为 n 的 χ^2 分布的 $1 - \alpha$ 分位数，这个是可以查表的。

1.4.2 F 分布

F 分布是建立在 χ^2 分布的基础之上的，我们先来讲一下它的定义：设随机变量 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$, X_1 与 X_2 独立，则称 $F = \frac{X_1/m}{X_2/n}$ 的分布是自由度为 m 与 n 的 F 分布，记为 $F \sim F(m, n)$ ，其中 m 称为分子自由度， n 称为分母自由度。其概率密度函数为

$$p_F(y) = \frac{\Gamma\left(\frac{m+n}{2}\right) \left(\frac{m}{n}\right)^{\frac{m}{2}}}{\Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right)} y^{\frac{m}{2}-1} \left(1 + \frac{m}{n}y\right)^{-\frac{m+n}{2}}$$

如果 X 是自由度为 m 和 n 的 F - 分布式随机变量, 则

$$E(X) = \frac{n}{n-2}, \quad n > 2, \quad \text{Var}(X) = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}, \quad n > 4$$

另外, 随机变量 $Y = 1/X$ 服从自由度为 n 和 m 的 F - 分布。

与 χ^2 分布相类似, 我们有:

当随机变量 $F \sim F(m, n)$ 时, 对给定 α ($0 < \alpha < 1$), 称满足概率等式 $P(F \leq F_{1-\alpha}(m, n)) = 1 - \alpha$ 的 $F_{1-\alpha}(m, n)$ 是自由度为 m 与 n 的 F 分布的 $1 - \alpha$ 分位数。

另外, 我们有这样的等式:

$$F_{\alpha}(n, m) = \frac{1}{F_{1-\alpha}(m, n)}$$

对于 α 值较小的情况可以通过查表得到结果。

利用 χ^2 分布的重要结论, 我们可以得到这样的推论:

引理 1.4.1. 设 $x_1, x_2, \dots, x_n$ 是来自 $\mathcal{N}(\mu_1, \sigma_1^2)$ 的样本, 均值为 $\bar{x}$, 无偏方差为 s_x^2 , $y_1, y_2, \dots, y_n$ 是来自 $\mathcal{N}(\mu_2, \sigma_2^2)$ 的样本, 均值为 $\bar{y}$, 无偏方差为 s_y^2 , 则

$$F = \frac{s_x^2/\sigma_1^2}{s_y^2/\sigma_2^2} \sim F(m-1, n-1)$$

这里提供了一种对两份样本的 σ_1^2 和 σ_2^2 的检验的方法, 如果我们不知道均值 μ , 则我们可以使用这个统计量来估计 σ_1^2/σ_2^2 。

1.4.3 t 分布

定义 1.4.2. 设随机变量 X_1 和 X_2 独立且 $X_1 \sim \mathcal{N}(0, 1)$, $X_2 \sim \chi^2(n)$, 则称 $t = \frac{X_1}{\sqrt{X_2/n}}$ 的分布为自由度为 n 的 t 分布, 记为 $t \sim t(n)$. 其密度函数为

$$p_t(y) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{y^2}{n}\right)^{-\frac{n+1}{2}}, \quad -\infty < y < \infty$$

对于一个服从 t 分布的随机变量, 他满足这样的性质:

1. 自由度为 1 的 t 分布就是标准柯西分布, 它的均值不存在
2. $\lim_{k \rightarrow \infty} f(x; k) = \phi(x)$.
3. $n > 1$ 时, 分布的数学期望存在且为 0, 密度函数在 $x = 0$ 处达到最大
4. $n > 2$ 时, 分布的方差存在, 且等于 $n/(n-2)$
5. 当自由度较大 (如 $n \geq 30$ 时), t 分布可以用 $\mathcal{N}(0, 1)$ 分布近似。

他有这样的两个推论：

引理 1.4.2. 设 $x_1, x_2, \dots, x_n$ 是来自正态分布 $\mathcal{N}(\mu, \sigma^2)$ 的一个样本， $\bar{x}$ 与 s^2 分别是该样本的样本均值与样本方差，则有

$$t = \frac{\sqrt{n}(\bar{x} - \mu)}{s} \sim t(n-1)$$

这里帮助我们建立了其他条件均未知时 μ 的区间估计方法，我们只需要利用样本的均值 $\bar{x}$ 和标准差 s 来建立统计量 $\frac{\sqrt{n}(\bar{x} - \mu)}{s}$ 来实现区间估计和正态检验。

引理 1.4.3. 和引理 1.4.1 相同，设 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ ，并记

$$s_w^2 = \frac{(m-1)s_x^2 + (n-1)s_y^2}{m+n-2} = \frac{\sum_{i=1}^m (x_i - \bar{x})^2 + \sum_{i=1}^n (y_i - \bar{y})^2}{m+n-2}$$

则

$$\frac{(\bar{x} - \bar{y}) - (\mu_1 - \mu_2)}{s_w \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(m+n-2)$$

这里提出的方法是当我们已知 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 时，我们将两份样本进行混合，得到的统计来解决 $\mu_1 - \mu_2$ 的值的估计。

最后，和前两个分布相同，我们有：当随机变量 $t \sim t(n)$ 时，对给定的 $\alpha (0 < \alpha < 1)$ 称满足概率公式 $P(t \leq_{1-\alpha}(n)) = 1 - \alpha$ 的 $t_{1-\alpha}(n)$ 是自由度为 n 的 t 分布的 $1 - \alpha$ 分位数，这个是通过查表获取的。

1.5 充分统计量

本节内容主要围绕“充分性”展开，他的定义是这样的：

定义 1.5.1. 设 $x_1, x_2, \dots, x_n$ 是来自某个总体的样本，总体分布函数为 $F(x; \theta)$ ，统计量 $T = T(x_1, x_2, \dots, x_n)$ 称为 θ 的充分统计量，如果在给定 T 的取值之后， $x_1, x_2, \dots, x_n$ 的条件分布与 θ 无关。

例 1.5.1. 设总体为两点分布 $b(1, \theta)$ ， $X_1, X_2, \dots, X_n$ 为样本，令 $T = X_1 + X_2 + \dots + X_n$ ，证明 T 是一个充分统计量。

但是，对于这个问题，如果我们要讨论 $S = X_1 + X_2$ 的分布律，结果就与 θ 相关了。

很明显，要求上面的式子是十分困难的，我们一般使用因子分解定理来解决问题：

定理 1.5.1. 设总体概率函数为 $f(x; \theta)$ ， $x_1, x_2, \dots, x_n$ 为样本，则 $T = T(x_1, x_2, \dots, x_n)$ (T 可以是一维的，也可以是多维的) 为充分统计量的充分必要条件是：存在两个函数 $g(t, \theta)$ 和 $h(x_1, x_2, \dots, x_n)$ 使得对任意的 θ 和任一组观测值 $x_1, x_2, \dots, x_n$ ，有

$$f(x_1, x_2, \dots, x_n; \theta) = g(T(x_1, x_2, \dots, x_n), \theta) h(x_1, x_2, \dots, x_n)$$

例 1.5.2. $X_1, \dots, X_n \sim B(1, \theta)$, 其中 $\theta \in [0, 1]$, 概率密度函数 $f(x; \theta) = \theta^x(1 - \theta)^{1-x}I_{\{0,1\}}(x)$, 找一个充分统计量。

此外, 我们有联合充分统计量:

定义 1.5.2. 令 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的随机样本, 其中 $\theta = (\theta_1, \dots, \theta_k)^T$, 统计量 $S_1, \dots, S_r$ 被称为联合充分统计量当且仅当给定 $S_1, \dots, S_r$ 的条件下, $X_1, \dots, X_n$ 的条件分布不依赖于 θ .

2 参数估计

在本章中，我们将利用样本的结果估计总体的数据情况，其主要的解决方式被分为点估计和区间估计。

2.1 点估计的概念与无偏性

首先我们介绍一下点估计是什么。

定义 2.1.1. 设 $x_1, x_2, \dots, x_n$ 是来自总体的一个样本，用于估计未知参数 θ 的统计量 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ 称为 θ 的估计量，或称为 θ 的点估计，简称估计。

看到这里我们可能比较纳闷的点就是 $\hat{\theta}$ 到底是什么样的形式，这里我们一般要求其满足无偏性：

定义 2.1.2. 设 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ 是 θ 的一个估计， θ 的参数空间为 Θ ，若对任意的 $\theta \in \Theta$ ，由

$$E_{\theta}(\hat{\theta}) = \theta$$

则称 $\hat{\theta}$ 是 θ 的无偏估计，否则称为有偏估计。

例 2.1.1. 令 $X_1, \dots, X_n$ 是来自总体 $\mathcal{N}(\mu, \sigma^2)$ 的随机样本，证明 $\hat{\sigma} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$ 不是 σ 的无偏估计。

从本质上来说无偏估计就是不存在系统误差，有偏估计就是存在系统误差。另外无偏性不具有不变性，也就是说，如果 $\hat{\theta}$ 是 θ 的无偏估计，一般而言，其函数 $g(\hat{\theta})$ 不是 $g(\theta)$ 的无偏估计，除非 $g(\theta)$ 是 θ 的线性函数。当然无偏估计不是总存在的，看下面的例子：

例 2.1.2. 设 X_1 是来自二项分布总体 $B(n, \theta)$ 的一个随机样本， $1/\theta$ 是否存在无偏估计？

最后我们来介绍一下有效性。

定义 2.1.3. 设 $\hat{\theta}_1, \hat{\theta}_2$ 是 θ 的两个无偏估计，如果对任意 $\theta \in \Theta$ 有

$$\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2)$$

且至少有一个 $\theta \in \Theta$ 使得上述不等号严格成立，则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

2.2 矩估计及相合性

首先我们讲一下替换定理，它的内容事实上很简单，就是用样本代表总体，用样本的特征反应总体的性质，它通常指这两句话：

1. 用样本均值 $\bar{x}$ 估计总体均值 $E(X)$.
2. 用样本矩的函数去替换相应总体矩的函数

根据这样的原理, 我们可以实现下面的转化:

1. 用样本均值 $\bar{x}$ 估计总体均值 $E(X)$.
2. 用样本方差 s^2 估计总体方差 $Var(X)$.
3. 用事件 A 出现的频率估计事件 A 发生的概率.
4. 用样本的 p 分位数估计总体的 p 分位数.

有了这样的理论基础, 我们可以考虑这样的问题:

例 2.2.1. 设总体为指数分布, 其密度函数为

$$p(x; \lambda) = \lambda e^{-\lambda x}, \quad x \geq 0$$

$x_1, x_2, \dots, x_n$ 为样本, 求 λ 的矩估计.

也就是说, 对于总体分布的未知量, 我们可以用样本的情况来估计原未知量的值, 前提是我们知道了这是怎样一个分布。

在上一章中, 我们讲到, 随着样本容量的增大, 取样所得的经验分布函数将无限接近于真实分布函数, 因此我们利用相合性来要求估计量随着样本量增加逼近真实值, 定义如下:

定义 2.2.1. 设 $\theta \in \Theta$ 为未知参数, $\hat{\theta}_n = \hat{\theta}_n(x_1, x_2, \dots, x_n)$ 是 θ 的一个估计量, n 是样本容量, 若对任何一个 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \geq \varepsilon) = 0$$

则称 $\hat{\theta}_n$ 为参数 θ 的相合估计。

从定义中我们不难发现, 相合性就是 $\hat{\theta}_n$ 依概率收敛于 θ , 所以其可以使用各种大数定律, 因此, 我们就可以得到这样的定理:

定理 2.2.1. 设 $\hat{\theta}_n = \hat{\theta}_n(x_1, x_2, \dots, x_n)$ 是 θ 的一个估计量, 若

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta, \quad \lim_{n \rightarrow \infty} Var(\hat{\theta}_n) = 0$$

则 $\hat{\theta}_n$ 是 θ 的相合估计。

例 2.2.2. 设 $x_1, x_2, \dots, x_n$ 是来自均匀总体 $U(0, \theta)$ 的样本, 证明: $x_{(n)}$ 是 θ 的相合估计。

另外, 我们介绍弱相合性:

定义 2.2.2. 令 $T_n = T_n(X_1, \dots, X_n)$ 是 $\tau(\theta)$ 的一个估计量, 其中 n 是样本量, 如果对任意的 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P_\theta[|T_n - \tau(\theta)| < \varepsilon] = 1, \quad \theta \in \Theta$$

则称 T_n 是 $\tau(\theta)$ 的弱相合估计。

与前文所提及的无偏性不同, 相合性具有不变性:

定理 2.2.2. 若 $\hat{\theta}_{n1}, \hat{\theta}_{n2}, \dots, \hat{\theta}_{nk}$ 分别是 $\theta_1, \theta_2, \dots, \theta_k$ 的相合估计, $\eta = g(\theta_1, \theta_2, \dots, \theta_k)$ 是 $\theta_1, \theta_2, \dots, \theta_k$ 的连续函数, 则 $\hat{\eta}_n = g(\hat{\theta}_{n1}, \hat{\theta}_{n2}, \dots, \hat{\theta}_{nk})$ 是 η 的相合估计。

由此, 我们不难发现, 矩估计一般都具有相合性:

1. 样本均值是总体均值的相合估计
2. 样本标准差是总体标准差的相合估计
3. 样本变异系数 $s/\bar{x}$ 是总体变异系数的相合估计。

例 2.2.3. 令 $X_1, \dots, X_n$ 是来自泊松总体

$$f(x; \lambda) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \dots$$

的随机样本, 证明 $T_n = n^{-1} \sum_{i=1}^n I_{\{0\}}(X_i)$ 是 $e^{-\lambda}$ 的无偏估计和相合估计。

2.3 最大似然估计与 EM 算法

最大似然估计的思想是这样的: 对某个时间做 n 次独立重复实验, 在这些实验中我们获得了一定的结果, 如 $\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$ 将这个作为最有可能发生的事件, 研究这个事件的概率, 由于其最容易发生, 所以我通过调整参数让上述事件发生的概率最大, 这就是最大似然估计

定义 2.3.1. 设总体的概率函数为 $p(x; \theta)$, $\theta \in \Theta$ 其中 θ 是一个未知参数或几个未知参数组成的参数向量, Θ 是参数空间, $x_1, x_2, \dots, x_n$ 是来自该总体的样本, 将样本的联合概率函数看成 θ 的函数, 用 $L(\theta; x_1, x_2, \dots, x_n)$ 表示, 简记为 $L(\theta)$,

$$L(\theta) = L(\theta; x_1, x_2, \dots, x_n) = p(x_1; \theta)p(x_2; \theta) \cdots p(x_n; \theta)$$

$L(\theta)$ 称为样本的似然函数, 如果某统计量 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ 满足

$$L(\hat{\theta}) = \max_{\theta \in \Theta} L(\theta)$$

则称 $\hat{\theta}$ 是 θ 的最大似然估计, 简记为 MLE 。

这里我们来做以下两条解释：

1. 对于大多数离散型独立重复实验，我们认为结果是服从二（多）项分布的，根据 $y = \log x$ 是在 $(0, +\infty)$ 上的增函数，我们用 $\log L(p)$ 代替 $L(p)$ ，用求和代替乘积，实现简化计算的目的
2. 对于多参数求极值问题，我们一般是通过对每个分量求偏导的形式完成的，具体步骤我们参考《数学分析入门》。

当然，对于连续型随机变量，我们也可以研究其概率密度函数。另外，我们也要从统计量出发考虑：

例 2.3.1. 设 $x_1, x_2, \dots, x_n$ 是来自均匀总体 $U(0, \theta)$ 的样本，试求 θ 的最大似然估计

例 2.3.2. 令 $X_1, \dots, X_n$ 是来自均匀分布 $U[\mu - \sqrt{3}\sigma, \mu + \sqrt{3}\sigma]$ 的随机样本，其中 $-\infty < \mu < \infty, \sigma > 0$ ，求 μ 和 σ 的 MLE。

这里，我们再讲一下最大似然估计的不变性：

定理 2.3.1. 设总体的概率函数 $f(x; \theta)$ ，假设参数 θ 是一维的，令 $\hat{\theta}(X_1, \dots, X_n)$ 是参数 θ 的极大似然估计，如果 $\tau(\theta)$ 是 θ 的单值可逆函数，则 $\tau(\theta)$ 的极大似然估计是 $\tau(\hat{\theta})$ 。

另外，在本节，我们简要介绍了似然函数较为复杂的 EM 算法，具体方式我们可以参考教材。下面介绍渐近正态性：

定义 2.3.2. 参数 θ 的相合估计 $\hat{\theta}_n$ 称为渐近正态的，若存在趋于 0 的非负常数序列 $\sigma_n(\theta)$ ，使得 $\frac{\hat{\theta}_n - \theta}{\sigma_n(\theta)}$ 依分布收敛于标准正态分布，这是也称 $\hat{\theta}_n$ 服从渐近正态分布 $\mathcal{N}(\theta, \sigma_n^2(\theta))$ 记为 $\hat{\theta}_n \sim AN(\theta, \sigma_n^2(\theta))$ ， $\sigma_n^2(\theta)$ 称为 $\hat{\theta}_n$ 的渐近方差。

或者我们有这样的符号表示：

定义 2.3.3. T_n 是 $\tau(\theta)$ 的估计量，如果 T_n 满足如下条件：

1. 当 $n \rightarrow \infty$

$$\sqrt{n}(T_n - \tau(\theta)) \rightarrow \mathcal{N}(0, \sigma^2(\theta))$$

2. $\forall \varepsilon > 0$

$$\lim_{n \rightarrow \infty} P_\theta[|T_n - \tau(\theta)| > \varepsilon] = 0, \theta \in \Theta$$

则称 T_n 是 $\tau(\theta)$ 的相合渐近正态估计，称 $\sigma^2(\theta)$ 为 $\sqrt{n}T_n$ 的渐近方差。

他有这样的一个判别方法：

定理 2.3.2. 设总体 X 有密度函数 $p(x; \theta)$ ， $\theta \in \Theta$ ， Θ 为非退化区间，假定

1. 对任意的 x , 偏导数 $\frac{\partial \log p}{\partial \theta}$, $\frac{\partial^2 \log p}{\partial \theta^2}$ 和 $\frac{\partial^3 \log p}{\partial \theta^3}$ 对所有 $\theta \in \Theta$ 都存在

2. $\forall \theta \in \Theta$, 有

$$\left| \frac{\partial p}{\partial \theta} \right| < F_1(x), \quad \left| \frac{\partial^2 p}{\partial \theta^2} \right| < F_2(x), \quad \left| \frac{\partial^3 \log p}{\partial \theta^3} \right| < F_3(x)$$

其中函数 $F_1(x)$, $F_2(x)$, $F_3(x)$ 满足

$$\int_{-\infty}^{\infty} F_1(x) dx < \infty, \quad \int_{-\infty}^{\infty} F_2(x) dx < \infty, \quad \sup_{\theta \in \Theta} \int_{-\infty}^{\infty} F_3(x) p(x; \theta) dx < \infty$$

3. $\forall \theta \in \Theta$, $0 < I(\theta) \equiv \int_{-\infty}^{\infty} \left(\frac{\partial \log p}{\partial \theta} \right)^2 p(x; \theta) dx < \infty$

若 $x_1, x_2, \dots, x_n$ 是来自该总体的样本, 则存在未知参数 θ 的最大似然估计 $\hat{\theta}_n = \hat{\theta}_n(x_1, x_2, \dots, x_n)$ 且 $\hat{\theta}_n$ 具有相合性和渐近正态性, $\hat{\theta}_n \sim AN\left(\theta, \frac{1}{nI(\theta)}\right)$.

定理 2.3.3. 假设 $X_1, \dots, X_n$ 是来自总体 $f(x; \theta)$ 的随机样本, $\hat{\theta}_n = \hat{\theta}_n(X_1, \dots, X_n)$ 是 θ 的极大似然估计, 如果概率密度函数 $f(x; \theta)$ 满足正则条件, 则

1. $\sqrt{n}(\hat{\theta} - \theta) \rightarrow \mathcal{N}(0, [I(\theta)]^{-1})$, 其中 $I(\theta)$ 称为 Fisher 信息量。

2. 极大似然估计 $\hat{\theta}_n$ 是相合估计。

例 2.3.3. 设 $X_1, \dots, X_n$ 是来自泊松分布总体 $P(\lambda)$ 的随机样本

(1) 求 λ 的矩估计和极大似然估计

(2) 求 λ 的 MLE 的渐近分布

例 2.3.4. 设 $\log X \sim \mathcal{N}(\mu, \sigma^2)$, 其中 $X_1, X_2, \dots, X_n$ 是来自 X 的样本, 求 μ 和 σ^2 以及 $\mathbf{E}(X)$ 的 MLE 。

例 2.3.5. 设 $X_1, X_2, \dots, X_n$ 是随机样本:

1. 证明 $\forall a_1, a_2, \dots, a_n$ 若满足 $\sum_{i=1}^n a_n = 1$, 则 $\sum_{i=1}^n a_i X_i$ 是总体期望 μ 的无偏估计。

2. 若 $\sum_{i=1}^n a_n = 1$, 证明当 $a_1 = a_2 = \dots = a_n = \frac{1}{n}$ 时, $\mathbf{Var}(\sum_{i=1}^n a_i X_i)$ 达到最大值。

2.4 最小方差无偏估计

如果我们要求 θ 的估计量 $\hat{\theta}$ 是 θ 的无偏估计时, 我们的首选方案是一致最小方差无偏估计, 其定义如下:

定义 2.4.1. 对参数估计问题, 设 $\hat{\theta}$ 是 θ 的一个无偏估计, 如果对另外任意一个 θ 的无偏估计 $\tilde{\theta}$, 在参数空间 Θ 上都有

$$\text{Var}_{\theta}(\hat{\theta}) \leq \text{Var}_{\theta}(\tilde{\theta})$$

则称 $\hat{\theta}$ 是 θ 的一致最小方差无偏估计, 简记为 *UMVUE*.

为了引出 *C-R* 不等式, 我们首先介绍正则条件:

定义 2.4.2. 设总体 X 的概率函数为 $f(x; \theta)$, $\theta \in \Theta$, $\Theta \in \mathbb{R}$ 是开区间, $f(x; \theta)$ 满足如下条件:

1. 对一切 $\theta \in \Theta$, $x \in \mathbb{R}$, 偏导数

$$\frac{\partial \log f(x; \theta)}{\partial \theta}, \frac{\partial^2 \log f(x; \theta)}{\partial \theta^2}, \frac{\partial^3 \log f(x; \theta)}{\partial \theta^3}$$

存在

2. 存在 $F_1(x)$, $F_2(x)$, $H(x)$, 对 $\forall \theta \in \Theta$ 和 $x \in \mathbb{R}$, 有

$$\left| \frac{\partial f(x; \theta)}{\partial \theta} \right| < F_1(x), \quad \left| \frac{\partial^2 f(x; \theta)}{\partial \theta^2} \right| < F_2(x), \quad \left| \frac{\partial^3 f(x; \theta)}{\partial \theta^3} \right| < H(x)$$

其中

$$\int_{-\infty}^{+\infty} F_i(x) dx < \infty, \quad i = 1, 2; \quad \int_{-\infty}^{+\infty} H(x) f(x) dx < M$$

3. 对一切 $\theta \in \Theta$, 有

$$0 < I(\theta) = \mathbf{E} \left[\left(\frac{\partial}{\partial \theta} \log f(X; \theta) \right)^2 \right] < \infty$$

则称随机变量 X 满足正则条件。

由此, 上面的 $I(\theta)$ 即 Fisher 信息量, 并且我们可以将 Fisher 信息量写成更易求解的形式:

$$I(\theta) = \mathbf{E} \left[\frac{\partial}{\partial \theta} \log p(x; \theta) \right]^2 = -\mathbf{E} \left[\frac{\partial^2}{\partial \theta^2} \log p(X; \theta) \right]$$

由此, 我们介绍这样的定理, 这也就是所谓的 *C-R* 下界:

定理 2.4.1. 设总体分布 $p(x; \theta)$ 满足正则条件, $x_1, x_2, \dots, x_n$ 是来自该总体的样本, $T = T(x_1, x_2, \dots, x_n)$ 是 $g(\theta)$ 的任一无偏估计, $g'(\theta) = \frac{\partial g(\theta)}{\partial \theta}$ 存在, 且对 Θ 中一切 θ , 对

$$g(\theta) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \dots, x_n) \prod_{i=1}^n p(x_i; \theta) dx_1 \cdots dx_n$$

的微商可在积分号下进行, 即

$$\begin{aligned} g'(\theta) &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \left(\prod_{i=1}^n p(x_i; \theta) \right) dx_1 \cdots dx_n \\ &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \dots, x_n) \left[\frac{\partial}{\partial \theta} \log \prod_{i=1}^n p(x_i; \theta) \right] \prod_{i=1}^n p(x_i; \theta) dx_1 \cdots dx_n \end{aligned}$$

对离散总体, 则将上述积分改为求和符号后, 等式仍然成立, 则有

$$\text{Var}(T) \geq [g'(\theta)]^2 / (nI(\theta))$$

称为 $C-R$ 不等式, $[g'(\theta)]^2 / (nI(\theta))$ 称为 $g(\theta)$ 的无偏估计方差的 $C-R$ 下界。

例 2.4.1. 令 $X_1, \dots, X_n$ 是来自 $f(x; \theta) = \theta e^{-\theta x} I_{(0, \infty)}(x)$ 的随机样本, 取 $\tau(\theta) = \theta$, θ^{-1} , 求 $\tau(\theta)$ 的无偏估计的方差的 $C-R$ 下界。

2.5 完备统计量与 UMVUE 的求解

首先, 我们在本节引入指数族的概念:

定义 2.5.1. 设 $\mathcal{F} = \{f(\cdot, \theta) : \theta \in \Theta\}$ 是定义在参数空间 Θ 的分布族, 对任意的 $\theta \in \Theta$, 选择合适的函数 $a(\cdot)$, $b(\cdot)$, $c(\cdot)$, $d(\cdot)$, 使得概率密度函数 $f(\cdot, \theta)$ (θ 是一维的) 可以表示成如下形式:

$$f(x; \theta) = a(\theta)b(x) \exp \{c(\theta)d(x)\}$$

则称此分布属于单参数指数型分布族, 简称指数族。

例 2.5.1. 证明指数分布 $\exp(\lambda)$ 、泊松分布 $Poi(\lambda)$ 、二项分布 $B(n, p)$ 、正态分布 $\mathcal{N}(\mu, 1)$ 都属于指数族。

另外值得指出的是, 结合因子分解定理, 对于样本 $X_1, X_2, \dots, X_n$ 我们有 $\sum_{i=1}^n d(x_i)$ 是充分统计量。

讲过单参数的指数族, 我们也可以引出多参数指数族的概念:

定义 2.5.2. 令 $\theta = (\theta_1, \dots, \theta_k)^T$, 如果选择合适的函数 $a(\cdot)$, $b(\cdot)$, $c(\cdot)$, $d(\cdot)$, $j = 1, 2, \dots, k$, 则概率函数族 $f(\cdot, \theta)$ 可以表示为

$$f(x; \theta) = a(\theta)b(x) \exp \left\{ \sum_{j=1}^k c_j(\theta)d_j(x) \right\}$$

则称 $f(x; \theta)$ 属于指数族。

例 2.5.2. 证明正态分布 $\mathcal{N}(\mu, \sigma^2)$ 与贝塔分布 $Beta(a, b)$ 属于多参数指数族。

下面我们介绍完备密度族。

定义 2.5.3. 令 $X_1, \dots, X_n$ 表示来自 $f(\cdot; \theta)$ 的随机样本, 参数空间为 Θ , 令 $T = T(X_1, \dots, X_n)$ 是统计量, T 的密度族是完备的当且仅当 $\forall \theta \in \Theta$, 对任何满足 $E[z(T)] = 0$ 的统计量 $z(T)$, 都有

$$P[z(T) = 0] \equiv 1, \forall \theta \in \Theta$$

例 2.5.3. 假设 $X_1, \dots, X_n$ 服从两点分布 $B(1, \theta)$.

1. $T = X_1 - X_2$ 是 0 的无偏估计, 但不是完备的
2. $T = \sum_{i=1}^n X_i$ 是完备的。

对于连续函数, 我们一般采用参数求导的方法:

例 2.5.4. 令 $X_1, \dots, X_n \stackrel{iid}{\sim} U(0, \theta)$, $\Theta = \{\theta : \theta > 0\}$, 证明顺序统计量 Y_n 是完备的。

有了这样的定义, 我们就可以引出下面这个定理, 进而帮助我们找到参数的 UMVUE .

定理 2.5.1. 令 $X_1, \dots, X_n$ 是来自 $f(\cdot; \theta)$ 的随机样本, $\theta \in \Theta$, 其中 Θ 是区间 (可能是无限的) 如果 $f(x; \theta) = a(\theta)b(x) \exp[c(\theta)d(x)]$, 即 $f(\cdot; \theta)$ 属于单参数指数族, 则 $\sum_{i=1}^n d(X_i)$ 是充分完备统计量。

定理 2.5.2. 令 $X_1, \dots, X_n$ 是来自 $f(\cdot; \theta)$ 的随机样本, 如果 $S = s(X_1, \dots, X_n)$ 是完备充分统计量, 令 $T^* = T^*(S)$ 是 S 的函数且是 $\tau(\theta)$ 的无偏估计, 则 T^* 是 $\tau(\theta)$ 的 UMVUE .

例 2.5.5. 假设 $X_1, \dots, X_n$ 是来自 $f(x; \lambda) = \frac{\lambda^x e^{-\lambda}}{x!}$ 的随机样本, 寻找 λ 和 $e^{-\lambda}$ 的 UMVUE .

此外, 我们还有这样的方法来寻找 UMVUE :

定理 2.5.3 (Rao-Blackwell). 令 $X_1, \dots, X_n$ 是来自总体 $f(x; \theta)$ 的随机样本, 其中 $\theta \in \Theta$, 令 $s_1(X_1, \dots, X_n), \dots, s_k(X_1, \dots, X_n)$ 是一组联合充分统计量, 令 $T = T(X_1, \dots, X_n)$ 是 $\tau(\theta)$ 的无偏估计, 定义 $T^* = \mathbf{E}[T|S_1, \dots, S_k]$, 则有

1. T^* 是统计量, 且是充分统计量 $S_1, \dots, S_k$ 的函数
2. $\mathbf{E}_\theta(T^*) = \tau(\theta)$ 即 T^* 是 $\tau(\theta)$ 的无偏估计
3. $\forall \theta \in \Theta, \mathbf{Var}(T^*) \leq \mathbf{Var}(T)$ 且存在某个 $\theta_0 \in \Theta$, 使得 $\mathbf{Var}_{\theta_0}(T^*) \leq \mathbf{Var}_{\theta_0}(T)$, 否则 T 以概率 1 等于 T^* .

基于这个定理, 我们介绍寻找 UMVUE 的第二种方法:

1. 找出 $\tau(\theta)$ 的一个无偏估计 T
2. 找充分统计量 $S_1, \dots, S_k$
3. 计算条件期望 $\mathbf{E}(T|S_1, \dots, S_k)$.
4. 令 $T' = \mathbf{E}(T|S_1, \dots, S_k)$, 因此 T' 是 $\tau(\theta)$ 的无偏估计, 且 $\mathbf{Var}(T') \leq \mathbf{Var}(T)$.

因此, 我们介绍两条思路:

1. 利用指数族的相关定理, 我们可以得到 $\sum_{i=1}^n d(X_i)$ 构成一个充分完备统计量, 对其做一定的线性变换就可以得到 UMVUE.
2. 我们可能可以发现 $\tau(\theta)$ 可能是随机变量取定某值时的概率, 此时我们就可以得到:

$$\mathbf{E}(I(X_1 = k)) = P(X = k) = \tau(\theta)$$

构成 $\tau(\theta)$ 的无偏估计, 则此时我们保证 $\mathbf{E}(I(X_1 = k | \sum_{i=1}^n d(X_i)))$ 构成 $\tau(\theta)$ 的 UMVUE, 此时我们将上式进行化简, 就可以得到最终的式子。

例 2.5.6. 假设 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x) = \theta e^{-\theta x} I_{(0, \infty)}(x)$, 寻找 $\theta, \frac{1}{\theta}$ 和 $e^{-k\theta} = P(X > k)$ 的 UMVUE.

例 2.5.7. 假设 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x) = \theta^x (1 - \theta)^{1-x}$, $x = 0, 1$, 证明

1. X_1 是 θ 的无偏估计
2. $S = \sum_{i=1}^n X_i$ 是充分统计量
3. $T' = \mathbf{E}(X_1 | \sum_{i=1}^n X_i)$ 是 θ 的无偏估计, 且 $\mathbf{Var}(T') \leq \mathbf{Var}(X_1)$.

2.6 损失函数

损失函数在深度学习的各类算法中具有十分重要的应用, 这里我们从数理统计的角度对这个内容做一定的了解。

定义 2.6.1. 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的随机样本, $T(X_1, \dots, X_n)$ 是 $\tau(\theta)$ 的估计, 称满足下列条件的实值函数 $\ell(t; \theta)$ 为损失函数:

1. 对所有可能的 t 和 $\theta \in \Theta$, $\ell(t; \theta) \geq 0$.
2. 当 $t = \tau(\theta)$ 时, $\ell(t; \theta) = 0$.

这里我们列举几个常见的损失函数:

1. 平方误差损失函数: $\ell(t; \theta) = (t - \tau(\theta))^2$.
2. 绝对误差损失函数: $|t - \tau(\theta)|$.
- 3.

$$\ell(t; \theta) = \begin{cases} A & |t - \tau(\theta)| > \varepsilon \\ 0 & |t - \tau(\theta)| \leq \varepsilon \end{cases} \quad \text{其中 } A > 0$$

4. $\ell(t; \theta) = \rho(\theta) |t - \tau(\theta)|^r$, 其中 $\rho(\theta) > 0$, $r > 0$.

5. Huber 损失函数

$$\ell(t; \theta) = \begin{cases} \frac{(t - \tau(\theta))^2}{2} & |t - \tau(\theta)| \leq c \\ c|t - \tau(\theta)| - \frac{c^2}{2} & |t - \tau(\theta)| > c \end{cases}, \quad \text{其中 } c > 0$$

6. Tukey 损失函数

$$\ell(t; \theta) = \begin{cases} \frac{c^2}{6} \left[1 - \left(1 - \frac{(t - \tau(\theta))^2}{c^2} \right)^3 \right] & |t - \tau(\theta)| \leq c \\ \frac{c^2}{6} & |t - \tau(\theta)| > c \end{cases} \quad \text{其中 } c > 0$$

7. 分位数损失函数 $\ell(t; \theta) = \gamma|t - \tau(\theta)|I(t \leq \tau(\theta)) + (1 - \gamma)|t - \tau(\theta)|I(t > \tau(\theta))$. 其中 $0 < \gamma < 1$

由此, 我们可以定义风险函数:

定义 2.6.2. 对于一个给定的损失函数 $\ell(t; \theta)$, 定义

$$\mathcal{R}_T(\theta) = \mathbf{E}[\ell(T; \theta)]$$

为估计量 $T = T(X_1, \dots, X_n)$ 的风险函数。

这里我们给出说明:

1. 风险函数是平均损失
2. 如果随机样本来自总体 $f(x; \theta)$, 则

$$\mathcal{R}_T(\theta) = \int \cdots \int \ell(T(x_1, \dots, x_n); \theta) \prod_{i=1}^n f(x_i; \theta) dx_1 \cdots dx_n$$

3. $T = T(X_1, \dots, X_n)$ 的密度函数是 $f_T(t)$, 则

$$\mathcal{R}_T(\theta) = \int \ell(t; \theta) f_T(t) dt$$

则有我们还有可容许估计和 Minimax 估计的概念:

定义 2.6.3. 一个估计 $T = T(X_1, \dots, X_n)$ 被称为可容许估计, 当且仅当没有其他估计的风险函数会比 T 的风险函数严格一致的小。

定义 2.6.4. 估计 T^* 称为 Minimax 估计当且仅当对每个估计 T^* ,

$$\sup_{\theta \in \Theta} \mathcal{R}_{T^*}(\theta) \leq \sup_{\theta \in \Theta} \mathcal{R}_T(\theta)$$

2.7 位置尺度不变性

定义 2.7.1. 估计量 $T = T(X_1, \dots, X_n)$ 被称为是位置不变的, 当且仅当对 $x_1, \dots, x_n$ 和 c 的所有取值,

$$T(x_1 + c, \dots, x_n + c) = T(x_1, \dots, x_n) + c$$

从这个定义出发, 我们不难发现, $\bar{X}$, $\frac{X_{(1)} + X_{(n)}}{2}$ 是位置不变的, 而 S^2 , $X_{(n)} - X_{(1)}$ 不是位置不变的。

定义 2.7.2. 令 $\{f(x; \theta), \theta \in \Theta\}$ 是密度族, 其中 $\Theta \subset \mathbb{R}$, 参数 θ 被称为位置参数当且仅当密度函数 $f(x; \theta)$ 可以表示为 $x - \theta$ 的函数, 即, 对某一函数 $h(\cdot)$, $f(x; \theta) = h(x - \theta)$, 等价的, θ 是随机变量 X 的密度函数 $f(x; \theta)$ 的位置参数, 当且仅当 $X - \theta$ 的分布不依赖于参数 θ .

从这个概念出发, 我们可以解决寻找均方误差最小的估计的问题。对于某统计量, 我们需要对其估计的好坏给出评价标准, 这里我们介绍均方误差, 他是这样定义的:

定义 2.7.3. $T = T(X_1, \dots, X_n)$ 是 $\tau(\theta)$ 的估计, 称 $E_\theta(T - \tau(\theta))^2$ 为 $T = T(X_1, \dots, X_n)$ 的均方误差。

这里我们指出, 如果 T 是 $\tau(\theta)$ 的无偏估计, 则 $MSE_T(\theta) = \text{Var}T$. 以此为标准, 我们定义一致均方误差估计:

定义 2.7.4. 设有样本 $x_1, x_2, \dots, x_n$ 对待估参数 θ , 设有一个估计类, 称 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 是该估计类中 θ 的一致最小均方误差估计, 如果对该估计类中另外任意一个 θ 的估计 $\tilde{\theta}$, 在参数空间 Θ 上都有

$$MSE_\theta(\hat{\theta}) \leq MSE_\theta(\tilde{\theta})$$

例 2.7.1. 设 $X_1, \dots, X_n$ 是来自总体 $f(x; \theta) = \frac{1}{\theta} I_{[0, \theta]}(x)$ 的随机样本, 其中 $\theta > 0$.

- (1) 求参数 θ 的矩估计 $\hat{\theta}$ 和 MLE $\tilde{\theta}$ 。
- (2) 计算估计 $\hat{\theta}$ 和 $\tilde{\theta}$ 的期望和均方误差
- (3) 判断 $\hat{\theta}$ 和 $\tilde{\theta}$ 是否是无偏估计, 如果不是无偏的, 做适当的修正得到 θ 的无偏估计
- (4) 判断 $\hat{\theta}$ 和 $\tilde{\theta}$ 是否为弱相合估计。

由此, 结合第二节的内容, 我们可以得到这样的定义:

定义 2.7.5. 令 $T_n = T_n(X_1, \dots, X_n)$ 是 $\tau(\theta)$ 的一个估计量, 其中 n 是样本量, 如果对任意的 $\theta \in \Theta$, 有

$$\lim_{n \rightarrow \infty} E_\theta[T_n - \tau(\theta)]^2 = 0$$

则称 T_n 是 $\tau(\theta)$ 的均方相合估计。

这里, 我们介绍一个求出一致均方误差最小估计的方法, 也即 Pitman 估计

定理 2.7.1. 令 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的随机样本, 其中 $\theta \in \Theta$ 是位置参数, 且 Θ 是实线, 参数 θ 的估计量

$$T(X_1, \dots, X_n) = \frac{\int_{-\infty}^{\infty} \theta \prod_{i=1}^n f(X_i; \theta) d\theta}{\int_{-\infty}^{\infty} \prod_{i=1}^n f(X_i; \theta) d\theta}$$

是 θ 所有位置不变的估计量中均方误差最小的估计。上述估计量被称为位置参数的 *Pitman* 估计。

这里我们指出, 位置参数的 Pitman 估计量是充分统计量的函数。

例 2.7.2. $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\theta, 1)$, 其中 θ 是位置参数, 求 θ 的 *Pitman* 估计。

例 2.7.3. $X_1, \dots, X_n \stackrel{iid}{\sim} U(\theta - \frac{1}{2}, \theta + \frac{1}{2})$, 其中 θ 是位置参数, 求 θ 的 *Pitman* 估计

相对应的, 我们介绍尺度不变性。

定义 2.7.6. 估计量 $T = T(X_1, \dots, X_n)$ 称为尺度不变的, 当且仅当对 $x_1, \dots, x_n$ 和 $c > 0$ 的所有取值:

$$T(cx_1, \dots, cx_n) = cT(x_1, \dots, x_n)$$

定义 2.7.7. 令 $\{f(x; \theta), \theta > 0\}$ 是密度族, 参数 θ 称为尺度参数当且仅当密度可以写为

$$f(x; \theta) = \frac{1}{\theta} h\left(\frac{x}{\theta}\right)$$

其中 $h(\cdot)$ 是某一密度函数, 等价的, θ 是随机变量 X 的密度函数 $f(x; \theta)$ 的尺度参数当且仅当 X/θ 的分布和参数 θ 无关。

定理 2.7.2. 令 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的随机样本, 其中 $x > 0$, $\theta > 0$ 是尺度参数, 在 θ 的所有尺度不变性的估计中

$$T(X_1, \dots, X_n) = \frac{\int_0^{+\infty} (1/\theta^2) \prod_{i=1}^n f(X_i; \theta) d\theta}{\int_0^{+\infty} (1/\theta^3) \prod_{i=1}^n f(X_i; \theta) d\theta}$$

是使损失函数 $\ell(t; \theta) = (t - \theta)^2 / \theta^2$ 的风险函数达到最小的估计量。将上述统计量称为尺度参数的 *Pitman* 估计。

这里我们也指出, 尺度参数的 Pitman 估计量是充分统计量的函数。

例 2.7.4. 设 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \theta) = \theta^{-1} I_{(0, \theta)}(x)$, 求尺度参数 θ 的 *Pitman* 估计。

例 2.7.5. 设 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \lambda) = \frac{1}{\lambda} e^{-\frac{x}{\lambda}} I_{(0, \infty)}(x)$, 求尺度参数 λ 的 *Pitman* 估计。

2.8 贝叶斯估计

对于贝叶斯估计, 我们将经典概率学派中的 $f(x; \theta)$ 改写为 $f(x|\theta)$, 在这样的条件下, 如果我们已知了 Θ 的密度函数 $g_{\Theta}(\theta)$, 我们将这个密度函数称为 Θ 的先验分布, 由此, 我们有了后验分布的概念。

定义 2.8.1. 设 $g_{\Theta}(\theta)$ 是 θ 的先验, 给定 $X_1 = x_1, \dots, X_n = x_n$ 的条件下 Θ 的条件密度 $f_{\Theta|X_1=x_1, \dots, X_n=x_n}(\theta|x_1, \dots, x_n)$ 被称为 Θ 的后验分布, 简记为 $f(\theta|x_1, \dots, x_n)$ 。

其中函数的计算方法是:

$$\begin{aligned} f(\theta|x_1, \dots, x_n) &= \frac{f_{X_1=x_1, \dots, X_n=x_n|\theta}(x_1, \dots, x_n|\theta)g_{\Theta}(\theta)}{f_{X_1, \dots, X_n}(x_1, \dots, x_n)} \\ &= \frac{\left[\prod_{i=1}^n f(x_i|\theta) \right] g_{\Theta}(\theta)}{\int \left[\prod_{i=1}^n f(x_i|\theta) \right] g_{\Theta}(\theta) d\theta} \\ &\propto L(\theta)g(\theta), \quad \text{其中 } L(\theta) \text{ 是似然函数} \end{aligned}$$

例 2.8.1. 令 $X_1, \dots, X_n \stackrel{iid}{\sim} P(\lambda)$, 且 λ 的先验分布为 $\Gamma(\alpha, \gamma)$, 计算 λ 的后验分布。

由此, 我们有后验贝叶斯估计:

定义 2.8.2. 令 $X_1, \dots, X_n$ 是来自 $f(x|\theta)$ 的随机样本, 其中 θ 是随机变量 Θ 的取值, 其密度函数为 $g_{\Theta}(\theta)$, $E[\tau(\Theta)|X_1 \dots X_n]$ 称为 $\tau(\theta)$ 关于先验 $g_{\Theta}(\theta)$ 的后验贝叶斯估计。

例 2.8.2. 设 $X_1, \dots, X_n$ 是来自 $f(x|\theta) = \binom{k}{x} \theta^x (1-\theta)^{k-x}$ 的随机样本, 先验分布为 $g(\theta) \sim B(a, b)$, 其中 a 和 b 是已知的, 求后验分布 $f(\theta|x_1, \dots, x_n)$ 和 θ 的后验贝叶斯估计。

例 2.8.3. 设 $X_1, \dots, X_n$ 是来自正态分布 $\mathcal{N}(\theta, \sigma^2)$ 的随机样本, 其中 σ^2 已知。

1. 当 $g(\theta) = 1$ 时, 求后验分布 $f(\theta|x_1, \dots, x_n)$ 和 θ 的后验贝叶斯估计
2. 当 $g(\theta) \sim \mathcal{N}(\mu, \sigma^2)$, 其中 μ 已知, 求后验分布 $f(\theta|x_1, \dots, x_n)$ 和 θ 的后验贝叶斯估计
3. 当 $g(\theta) \sim \mathcal{N}(\mu, \tau^2)$, 其中 μ 和 τ^2 已知, 求后验分布 $f(\theta|x_1, \dots, x_n)$ 和 θ 的后验贝叶斯估计。

下面我们介绍几种先验分布。

1. 无信息先验: 如果 Θ 的取值是有限个, 如 $\Theta = a_1, a_2, \dots, a_m$, 则我们取先验分布为

$$P(\Theta = a_i) = \frac{1}{m}, i = 1, 2, \dots, m$$

如果 Θ 的取值范围是 $[a, b]$, 其中 $-\infty < a < b < \infty$, 则我们可以取 $g_{\Theta}(\theta) \sim U[a, b]$.

如果 Θ 的取值范围是 $(-\infty, +\infty)$ 则 $g_{\Theta}(\theta)$ 取广义先验密度, 即 $g_{\Theta}(\theta) \geq 0$, $\int g_{\Theta}(\theta) d\theta = +\infty$, 且满足后验分布是一个真实的密度函数。

2. Jeffrey 无信息先验: $\{f(x|\theta) : \theta \in \Theta\}$ 满足正则条件, 取先验分布

$$g(\theta) \propto |I(\theta)|^{\frac{1}{2}}$$

其中 $I(\theta)$ 为 Fisher 信息量。

3. 共轭先验: 若后验分布和先验分布属于同一个分不足, 则称该先验分布为共轭先验。

例 2.8.4. 令 $X_1, \dots, X_n$ 是来自 $\mathcal{N}(\mu, \sigma^2)$ 的随机样本。令 $\theta = (\mu, \sigma)$, 找 (μ, σ) 的 Jeffrey 无信息先验。

例 2.8.5. 设 $X_1, \dots, X_n$ 是来自正态分布 $\mathcal{N}(\theta, \sigma^2)$ 的随机样本, 其中 σ^2 已知。

(1) 当 $g(\theta) = 1$ 时, 求后验分布 $f(\theta|x_1, \dots, x_n)$ 和 θ 的后验贝叶斯估计

(2) 当 $g(\theta) \sim \mathcal{N}(\mu, \sigma^2)$, 其中 μ 已知, 求后验分布 $f(\theta|x_1, \dots, x_n)$ 和 θ 的后验贝叶斯估计

(3) 当 $g(\theta) \sim \mathcal{N}(\mu, \tau^2)$, 其中 μ 和 τ^2 已知, 求后验分布 $f(\theta|x_1, \dots, x_n)$ 和 θ 的后验贝叶斯估计。

下面我们介绍利用损失函数求解贝叶斯估计的方法。

定义 2.8.3. 设 $X_1, \dots, X_n$ 是来自 $f(x|\theta)$ 的随机样本, 其中 θ 是随机变量 Θ 的取值, 其先验分布为 $g(\theta) = g_{\Theta}(\theta)$, 在估计 $\tau(\theta)$ 时, 设 $\ell(t; \theta)$ 是损失函数, $\tau(\theta)$ 的估计量 $T = T(X_1, \dots, X_n)$ 的风险函数表示为 $\mathcal{R}_T(\theta)$, 则

$$\eta_{\ell, g}(T) = \int_{\Theta} \mathcal{R}_T(\theta) g(\theta) d\theta$$

称为估计量 $T = T(X_1, \dots, X_n)$ 关于损失函数 $\ell(t; \theta)$ 和先验分布 $g(\theta)$ 的贝叶斯风险。

定义 2.8.4. $\tau(\theta)$ 关于损失函数 $\ell(t; \theta)$ 和先验分布 $g(\theta)$ 的估计 $T^* = T_{\ell, g}^*(X_1, \dots, X_n)$ 如果具有最小贝叶斯风险, 则称 $T_{\ell, g}^*$ 是贝叶斯估计, 或者定义为: $\tau(\theta)$ 如果满足其贝叶斯风险比 $\tau(\theta)$ 其他任意一个估计 $T = T(X_1, \dots, X_n)$ 的贝叶斯风险都小, 即

$$\eta_{\ell, g}(T^*) \leq \eta_{\ell, g}(T)$$

则称 $T_{\ell, g}^*$ 是 $\tau(\theta)$ 的贝叶斯估计。

这里我们可以证明: $\tau(\theta)$ 关于平方损失的贝叶斯估计和 $\tau(\theta)$ 的后验贝叶斯估计相同, θ 关于绝对偏差损失函数的贝叶斯估计是 Θ 的后验分布的中位数。另外, 我们有这样的方法求解贝叶斯估计:

定理 2.8.1. 令 $X_1, \dots, X_n$ 是来自 $f(x|\theta)$ 的随机样本, 令 $g(\theta)$ 是 Θ 的密度函数, 进一步的, 令 $\ell(t; \theta)$ 是用于估计 $\tau(\theta)$ 的损失函数, $\tau(\theta)$ 的贝叶斯估计 $T^*(x_1, \dots, x_n)$ 可从如下式子对 $T(x_1, \dots, x_n)$ 最小化得到:

$$\int_{\Theta} \ell(T(x_1, \dots, x_n); \theta) f(\theta|x_1, \dots, x_n) d\theta$$

例 2.8.6. 假设 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x|\theta) = \frac{1}{\theta} I_{(0,\theta)}(x)$, Θ 的密度函数 $g(\theta) = I_{(0,1)}(\theta)$, 设损失函数 $\ell(t; \theta) = (t - \theta)^2 / \theta^2$, 求 θ 的贝叶斯估计。

在本章的最后我们介绍 Minimax 估计的求解方法:

定理 2.8.2. 如果贝叶斯估计 $T^* = T^*(X_1, \dots, X_n)$ 的风险函数是常数, 即 $\mathcal{R}_{T^*}(\theta) \equiv C$, 则 T^* 是 Minimax 估计。

因此寻找 Minimax 估计有这样的步骤:

1. 根据先验分布 $g(\theta)$ 和总体分布 $f(x|\theta)$, 计算后验分布 $f(\theta|x_1, \dots, x_n)$
2. 根据损失函数 $\ell(t; \theta)$ 计算 θ 的贝叶斯估计 $T_B = T(X_1, \dots, X_n)$
3. 根据损失函数计算贝叶斯估计 T_B 的风险函数 $\mathcal{R}(\theta) = \mathbf{E}(\ell(T; \theta))$
4. 让风险函数 $\mathcal{R}(\theta) = C$ 以确定函数中的参数
5. 带入贝叶斯估计, 此时的估计就是 Minimax 估计

例 2.8.7. 假设随机样本来自伯努利分布 $B(1, \theta)$, Θ 的后验分布为贝塔分布 $Beta(a, b)$, 基于平方损失函数, 寻找 θ 的 Minimax 估计。

2.9 区间估计

我们对某个统计量的点估计往往存在误差, 如果我们将估计值控制在某个区间之内, 可以简化我们的一些研究, 因此在此我们引入置信区间的概念:

定义 2.9.1. 设 θ 是总体的一个参数, 其参数空间为 Θ , $x_1, \dots, x_n$ 是来自该总体的样本, 对给定的一个 α ($0 < \alpha < 1$), 假设有两个统计量 $\hat{\theta}_L(x_1, \dots, x_n)$ 和 $\hat{\theta}_U(x_1, \dots, x_n)$, 若对任意的 $\theta \in \Theta$, 有

$$P_{\theta}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) \geq 1 - \alpha$$

则称随机区间 $[\hat{\theta}_L, \hat{\theta}_U]$ 为 θ 的置信水平为 $1 - \alpha$ 的置信区间, 或简称 $[\hat{\theta}_L, \hat{\theta}_U]$ 是 θ 的 $1 - \alpha$ 置信区间, $\hat{\theta}_L$ 和 $\hat{\theta}_U$ 分别称为 θ 的置信下限和置信上限。

上面这条定义适用于离散随机变量的情形, 下面的适用于连续型随机变量:

定义 2.9.2. 同上, 如对给定的 α ($0 < \alpha < 1$), 对任意的 $\theta \in \Theta$, 有

$$P_{\theta}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) = 1 - \alpha$$

则称 $[\hat{\theta}_L, \hat{\theta}_U]$ 为 θ 的 $1 - \alpha$ 同等置信区间。

另外, 我们也有:

定义 2.9.3. 设 $\hat{\theta}_L = \hat{\theta}_L(x_1, \dots, x_n)$ 是统计量, 对给定的 $\alpha \in (0, 1)$ 和任意的 $\theta \in \Theta$, 有

$$P_{\theta}(\hat{\theta}_L \leq \theta) \geq 1 - \alpha, \quad \forall \theta \in \Theta$$

则称 $\hat{\theta}_L$ 为 θ 的置信水平为 $1 - \alpha$ 的置信下限, 假设等号对一切 $\theta \in \Theta$ 成立, 则称 $\hat{\theta}_L$ 为 θ 的 $1 - \alpha$ 同等置信下限。

定义 2.9.4. 设 $\hat{\theta}_U = \hat{\theta}_U(x_1, \dots, x_n)$ 是统计量, 对给定的 $\alpha \in (0, 1)$ 和任意的 $\theta \in \Theta$, 有

$$P_{\theta}(\hat{\theta}_U \geq \theta) \geq 1 - \alpha, \quad \forall \theta \in \Theta$$

则称 $\hat{\theta}_U$ 为 θ 的置信水平为 $1 - \alpha$ 的置信上限, 假设等号对一切 $\theta \in \Theta$ 成立, 则称 $\hat{\theta}_U$ 为 θ 的 $1 - \alpha$ 同等置信上限。

有了这样的定义, 我们来介绍如何构造置信区间, 最常用的方法是枢轴量法, 他是这样计算的:

1. 设法构造一个样本和 θ 的函数 $G = G(x_1, \dots, x_n)$ 使得 G 的分布不依赖于位置参数, 一般称具有这种性质的 G 为枢轴量。
2. 适当的选择两个常数 c, d , 使对给定的 α ($0 < \alpha < 1$), 有

$$P(c \leq G \leq d) = 1 - \alpha$$

在离散场合, 上式等号改为 $\geq$ 。

3. 假如能将 $c \leq G \leq d$ 进行不等式等价变形化为 $\hat{\theta}_L \leq \theta \leq \hat{\theta}_U$, 则有

$$P_{\theta}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) = 1 - \alpha$$

这表明 $[\hat{\theta}_L, \hat{\theta}_U]$ 是 θ 的 $1 - \alpha$ 同等置信区间。

例 2.9.1. 设 $x_1, \dots, x_n$ 是来自均匀总体 $U(0, \theta)$ 的一个样本, 试对设定的 α ($0 < \alpha < 1$) 给出 θ 的 $1 - \alpha$ 同等置信区间

下面我们来讨论单个正态总体参数的置信区间:

1. σ 已知时 μ 的置信区间：我们用标准正态分布 $G = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ ，可以得出 μ 的 $1 - \alpha$ 同等置信区间为

$$[\bar{x} - u_{1-\alpha/2}\sigma/\sqrt{n}, \bar{x} + u_{1-\alpha/2}\sigma/\sqrt{n}]$$

样本量越大，区间越短，精确度越高， σ 越大，区间越长，精度更低，置信系数越大，区间长度越大。

例 2.9.2. 设总体为正态分布 $\mathcal{N}(\mu, 1)$ ，为得到 μ 的置信水平为 0.95 的置信区间且长度不超过 1.2，样本容量应为多大。

2. σ 未知时 μ 的置信区间：利用 $t = \frac{\sqrt{n}(\bar{x} - \mu)}{s} \sim t(n-1)$ ，我们有 μ 的 $1 - \alpha$ 置信区间为

$$[\bar{x} - t_{1-\alpha/2}(n-1)s/\sqrt{n}, \bar{x} + t_{1-\alpha/2}(n-1)s/\sqrt{n}]$$

此处 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ 是 σ^2 的无偏估计。

3. μ 已知时 σ^2 的置信区间：利用 $\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi^2(n)$ ，我们有置信区间为

$$\left(\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\alpha/2}^2(n)}, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\alpha/2}^2(n)} \right)$$

4. μ 未知时 σ^2 的置信区间：结合 $\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$ ，我们在 χ^2 分布两侧选取 $\alpha/2$ 的部分，得到置信区间

$$[(n-1)s^2/\chi_{1-\alpha/2}^2(n-1), (n-1)s^2/\chi_{\alpha/2}^2(n-1)]$$

这里我们可以将第二类和第三类结合，看下面这个例子：

例 2.9.3. 设 $X_1, \dots, X_n$ 是来自 $\mathcal{N}(\mu, \sigma^2)$ 的样本，其中 μ 和 σ^2 未知，求出他们的置信区间，这里事实上我们只需要将上面的第二种和第三种结合起来就可以了，并且我们可以得到共同置信区间

$$P\left(a < \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} < b; c < \frac{(n-1)s^2}{\sigma^2} < d\right) = \alpha_1 \alpha_2$$

另外，我们也可以研究两个正态总体下的置信区间。

1. $\mu_1 - \mu_2$ 的置信区间

- σ_1^2 和 σ_2^2 已知时：此时我们有 $\bar{x} - \bar{y} \sim \mathcal{N}\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}\right)$ ，并取枢轴量为

$$u = \frac{\bar{x} - \bar{y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}} \sim \mathcal{N}(0, 1)$$

有置信区间为

$$\left[\bar{x} - \bar{y} - u_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}, \bar{x} - \bar{y} + u_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}} \right]$$

- $\sigma_1^2/\sigma_2^2 = \sigma^2$ 未知时的置信区间：我们构造枢轴量

$$t = \sqrt{\frac{mn(m+n-2)}{m+n}} \frac{\bar{x} - \bar{y} - (\mu_1 - \mu_2)}{\sqrt{(m-1)s_x^2 + (n-1)s_y^2}} \sim t(m+n-2)$$

如果记 $s_w^2 = \frac{(m-1)s_x^2 + (n-1)s_y^2}{m+n-2}$ ，则 $\mu_1 - \mu_2$ 的 $1-\alpha$ 置信区间为

$$\left[\bar{x} - \bar{y} - \sqrt{\frac{m+n}{mn}} s_w t_{1-\alpha/2}(m+n-2), \bar{x} - \bar{y} + \sqrt{\frac{m+n}{mn}} s_w t_{1-\alpha/2}(m+n-2) \right]$$

- $\sigma_2^2/\sigma_1^2 = c$ 已知时：与前面的方法基本类似，我们构造枢轴量

$$t = \frac{\bar{x} - \bar{y} - (\mu_1 - \mu_2)}{\sqrt{(m-1)s_x^2 + (n-1)s_y^2/c}} \sqrt{\frac{mn(m+n-2)}{mc+n}} \sim t(m+n-2)$$

记 $s_w^2 = \frac{(m-1)s_x^2 + (n-1)s_y^2/c}{m+n-2}$ ，则 $\mu_1 - \mu_2$ 的 $1-\alpha$ 置信区间为

$$\left[\bar{x} - \bar{y} - \sqrt{\frac{mc+n}{mn}} s_w t_{1-\alpha/2}(m+n-2), \bar{x} - \bar{y} + \sqrt{\frac{mc+n}{mn}} s_w t_{1-\alpha/2}(m+n-2) \right]$$

- 当 m 和 n 都很大时的近似置信区间：利用中心极限定理：

$$\frac{\bar{x} - \bar{y} - (\mu_1 - \mu_2)}{\sqrt{\frac{s_x^2}{m} + \frac{s_y^2}{n}}} \sim \mathcal{N}(0, 1)$$

我们有置信区间为

$$\left[\bar{x} - \bar{y} - u_{1-\alpha/2} \sqrt{\frac{s_x^2}{m} + \frac{s_y^2}{n}}, \bar{x} - \bar{y} + u_{1-\alpha/2} \sqrt{\frac{s_x^2}{m} + \frac{s_y^2}{n}} \right]$$

- 一般情况下的近似置信区间：这里介绍一种近似方法： $s_0^2 = s_x^2/m + s_y^2/n$ ，取近似枢轴量

$$T = [\bar{x} - \bar{y} - (\mu_1 - \mu_2)]/s_0$$

此时 T 近似服从自由度为 l 的 t 分布，其中 l 由公式

$$l = \frac{s_0^4}{\frac{s_x^4}{m^2(m-1)} + \frac{s_y^4}{n^2(n-1)}}$$

我们用 l 最接近的整数代替 l ，则 $T \sim t(l)$ ，从而有置信区间为

$$[\bar{x} - \bar{y} - s_0 t_{1-\alpha/2}(l), \bar{x} - \bar{y} + s_0 t_{1-\alpha/2}(l)]$$

2. σ_1^2/σ_2^2 的置信区间：我们构造枢轴量

$$F = \frac{s_x^2/\sigma_1^2}{s_y^2/\sigma_2^2} \sim F(m-1, n-1)$$

得到置信区间

$$\left[\frac{s_x^2}{s_y^2} \frac{1}{F_{1-\alpha/2}(m-1, n-1)}, \frac{s_x^2}{s_y^2} \frac{1}{F_{\alpha/2}(m-1, n-1)} \right]$$

这里我们指出，当我们从一个总体中抽取样本时，如果总体存在一个连续的累计密度函数，则其枢轴量存在，且可以是

$$\prod_{i=1}^n F(X_i; \theta) \quad \text{或} \quad -\sum_{i=1}^n \log F(X_i; \theta)$$

例 2.9.4. 设 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \theta) = \theta x^{\theta-1} I_{(0,1)}(x)$ ，找出 θ 的 100γ 分位置信区间。

此时，如果 θ 是一个位置参数，则 $X_i - \theta$ 独立于 θ ，于是且构成了一个枢轴量，并且其变换也构成一个枢轴量，如 $\sum_{i=1}^n X_i - n\theta$, $Y_1 + Y_n - 2\theta$ 。此外，如果 θ 是一个尺度参数，那么 X_i/θ 与 θ 独立，因此 $\sum_{i=1}^n X_i/\theta$, Y_1/θ , Y_n/θ ，构成一个枢轴量法。

例 2.9.5. 假设 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \lambda) = \lambda e^{-\lambda x}$, $x > 0$, $\lambda > 0$ ，找出一个 λ 的 $100(1-\alpha)$ 分位置信区间。

接下来，我们看大样本下的置信区间。首先我们回顾 Slutsky Lemma:

定理 2.9.1. 假设 $\{Z_n\}$ 和 $\{U_n\}$ 是两个随机变量序列，且 $Z_n \xrightarrow{d} Z$, $U_n \xrightarrow{p} c$ ，其中 c 是一个常数，则

$$1. Z_n + U_n \xrightarrow{d} Z + c$$

$$2. Z_n U_n \xrightarrow{d} cZ$$

$$3. Z_n/U_n \xrightarrow{d} Z/c$$

假设 $\hat{\theta}_n$ 是参数 θ 满足 $f(\cdot; \theta)$ 的一个 MLE，如果 $f(\cdot; \theta)$ 满足一些正则条件，则我们有

$$P\left(-z_{(1+\gamma)/2} < \frac{\hat{\theta}_n - \theta}{\sigma_n(\theta)} < z_{(1+\gamma)/2}\right)$$

其中 $z_{(1+\gamma)/2}$ 是 $\mathcal{N}(0, 1)$ 的 $(1+\gamma)/2$ 分位数。

例 2.9.6. 假设 $X_1, \dots, X_n \stackrel{iid}{\sim} B(1, \theta)$ ，求 θ 的置信系数为 γ 的置信区间。

3 假设检验

3.1 假设检验的基本思想与概念

从本节开始我们进入假设检验的学习，首先我们来明确假设检验的步骤是什么

1. 建立假设：这里我们做出一个原假设 Θ_0 ，设 $\Theta_1 = \Theta - \Theta_0$ 为对立假设，我们就可以研究这样一对假设

$$H_0: \theta \in \Theta_0 \quad \text{vs} \quad H_1: \theta \in \Theta_1$$

2. 选择检验统计量，给出拒绝域的形式：我们通过获取具体的样本，我们可以将样本空间划分成两个互不相交的部分 W 和 $\bar{W}$ ，当样本属于 W 时，拒绝 H_0 ，否则接受 H_0 。

这里，令 $\mathcal{X}$ 为样本空间，即 $\mathcal{X} = \{(x_1, \dots, x_n) : (x_1, \dots, x_n) \text{ 是 } (X_1, \dots, X_n) \text{ 的所有可能取值}\}$ 。则 $C = \{(x_1, \dots, x_n) : (x_1, \dots, x_n) \in W\}$ 是拒绝域， $\bar{C} = \{(x_1, \dots, x_n) : (x_1, \dots, x_n) \notin W\}$ 是接受域。下面我们来简要介绍一下随随机检验的定义：

定义 3.1.1. 如果统计假设 H 的一个检验 T 由函数

$$\psi_T(x_1, \dots, x_n) = P(H \text{ 被拒绝} | (x_1, \dots, x_n) \text{ 被观测到})$$

确定，则称 T 为随机检验， $\psi_T(x_1, \dots, x_n)$ 为检验 T 的临界函数

例 3.1.1. 令 $X_1, \dots, X_{10}$ 是来自 $f(x; \theta) = \theta^x(1 - \theta)^{1-x}$ 的随机样本，其中 $x = 0$ 或 1 ，检验 $\theta < 1/2$ 。

3. 选择显著性水平。在进行检验时，我们同样也会遇见判断错误的情形，即当 $\theta \in \Theta_0$ 时，样本错误的落入拒绝域 W 中，此时我们称这类错误为第一类错误，相应的，当 $\theta \in \Theta_1$ 时，样本错误的落入接受域 $\bar{W}$ 中，我们称这类错误为第二类错误。这里我们值得注意的时，我们无法找到一个检验，使犯错的概率尽可能小，为了介绍这一点，我们引入势函数的概念：

定义 3.1.2. 设检验问题

$$H_0: \theta \in \Theta_0 \quad \text{vs} \quad H_1: \theta \in \Theta_1$$

的拒绝域为 W ，则样本观测值 X 落在拒绝域 W 内的概率称为该检验的势函数，记为

$$g(\theta) = P_\theta(X \in W), \quad \theta \in \Theta = \Theta_0 \cup \Theta_1$$

在这份定义的解释下，上面的说法就很显然了，于是我们选择折中的方案，仅考虑犯第一类错误的概率，即

定义 3.1.3. 对检验问题 $H_0: \theta \in \Theta_0 \quad \text{vs} \quad H_1: \theta \in \Theta_1$ ，如果一个检验满足对任意的 $\theta \in \Theta_0$ 都有

$$g(\theta) \leq \alpha$$

则称该检验是显著性水平为 α 的显著性检验，简称水平为 α 的检验。

例 3.1.2. 令 $X_1, \dots, X_n$ 是来自 $\mathcal{N}(\theta, 25)$ 的随机样本, 考虑 $H_0: \theta \leq 17$ 和检验 T : 拒绝 H_0 当且仅当 $\bar{X}_n > 17 - 5/\sqrt{n}$, 并求出检验 T 的检验水平。

4. 给出拒绝域, 并作出判断

3.2 似然比检验与复合假设检验

在本节我们将介绍在假设检验中地位有如 MLE 在点估计中地位的似然比检验, 首先是简单似然比检验:

定义 3.2.1. 设 $X_1, \dots, X_n$ 是来自 $f_0(x)$ 或 $f_1(x)$ 的随机样本, 令 $L_j = L_j(x_1, \dots, x_n)$ 是来自总体 $f_j(x)$ 的样本的似然函数, $j = 1, 2$, 称 $H_0: X_i \sim f_0(x)$ vs $H_1: X_i \sim f_1(x)$ 的检验为简单似然比检验:

$$\lambda = \lambda(x_1, \dots, x_n) = \frac{\prod f_0(x_i)}{\prod f_1(x_i)} = \frac{L_0(x_1, \dots, x_n)}{L_1(x_1, \dots, x_n)} = \frac{L_0}{L_1}$$

设 k 为非负常数, 检验 T 由如下定义: 如果 $\lambda < k$ 则拒绝 H_0 , 如果 $\lambda > k$ 则接受 H_0 , 如果 $\lambda = k$ 则随机接受 H_0 .

从这个定义中我们不难发现, 如果这个检验是一个好的检验, 那么其值应当尽可能地大, 这也就是所谓的最优势检验:

定义 3.2.2. 对 $H_0: \theta \in \Theta_0$ vs $H_1: \theta \in \Theta_1$ 的检验 T^* 被称为检验水平为 α ($0 < \alpha < 1$) 的最优势检验 (MPT), 当且仅当 $\pi_{T^*}(\theta_0) = \alpha$ 且对任何满足条件 $\pi_T(\theta_0) \leq \alpha$ 的检验 T , $\pi_{T^*}(\theta_1) \geq \pi_T(\theta_1)$

事实上, 我们一般通过下面这条引理判断 MPT:

引理 3.2.1 (Neyman-Pearson). 令 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的随机样本, 其中 θ 等于 θ_0 或者 θ_1 , 检验假设

$$H_0: \theta \in \Theta_0 \quad \text{vs} \quad H_1: \theta \in \Theta_1$$

令 $0 < \alpha < 1$ 是固定的, k^* 是正常数, C^* 是 $\mathcal{X}$ 的子集, 且满足

$$(1) P_{\theta_0}[(X_1, \dots, X_n) \in C^*] = \alpha$$

$$(2) \lambda = \frac{L_0(\theta_0; x_1, \dots, x_n)}{L_1(\theta_1; x_1, \dots, x_n)} = \frac{L_0}{L_1} \leq k^*, \text{ 如果 } (x_1, \dots, x_n) \in C^*, \text{ 或者如果 } (x_1, \dots, x_n) \in \bar{C}^*, \lambda > k^*.$$

则相应于拒绝域 C^* 的检验 T^* 是检验水平为 α 的最优势检验。

例 3.2.1. 令 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \theta) = \theta e^{-\theta x} I_{(0, \infty)}(x)$, 其中 $\theta = \theta_0$ 或 $\theta = \theta_1$, 检验 $H_0: \theta = \theta_0$ vs $H_1: \theta = \theta_1$, 其中 $\theta_0 < \theta_1$, 求其检验水平为 α 的最优势检验。

例 3.2.2. 令 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \theta) = \theta^x(1-\theta)^{1-x}I_{(0,1)}(x)$, 其中 $\theta = \theta_0$ 或 $\theta = \theta_1$, 检验 $H_0: \theta = \theta_0$ vs $H_1: \theta = \theta_1$, 其中 $\theta_0 < \theta_1$.

当然, 我们可以将简单似然比推广至广义似然比:

定义 3.2.3. 随机样本 $X_1, \dots, X_n$ 的联合密度函数为 $f(x_1, \dots, x_n; \theta)$, 其中 $\theta \in \Theta$, 令 $L(\theta; x_1, \dots, x_n)$ 为样本的似然函数, 定义广义似然比

$$\lambda = \lambda_n = \lambda(x_1, \dots, x_n) = \frac{\sup_{\theta \in \Theta_0} L(\theta; x_1, \dots, x_n)}{\sup_{\theta \in \Theta} L(\theta; x_1, \dots, x_n)} = \frac{\sup_{\theta \in \Theta_0} L(\theta)}{\sup_{\theta \in \Theta} L(\theta)}$$

这里我们有几点注意:

1. 注意 λ 是样本 $x_1, \dots, x_n$ 的函数, 且 $0 \leq \lambda \leq 1$
2. 当观测数据 $x_1, \dots, x_n$ 用其相应的随机样本 $X_1, \dots, X_n$ 代替, 我们用 $\Lambda = \Lambda(X_1, \dots, X_n)$ 代替 λ , 此时 Λ 是统计量
3. 拒绝 H_0 当且仅当 $\lambda \leq \lambda_0$, 其中 λ_0 是一个固定的常数且满足 $0 < \lambda_0 < 1$
4. 当 $\Theta = \{\theta_0, \theta_1\}$ 时, 广义似然比不会简化为简单似然比
5. 广义似然比 Λ 的分母是似然函数在最大似然估计值处的取值。
6. 参数 θ 可以是向量。

例 3.2.3. 设 $X_1, \dots, X_n$ 是来自正态总体 $\mathcal{N}(\mu, \sigma^2)$ 的随机样本, 参数 μ 和 σ^2 未知, 用似然比检验如下统计假设:

$$H_0: \mu \leq \mu_0 \text{ vs } H_1: \mu > \mu_0$$

另外我们简单介绍一下渐进卡方分布:

定理 3.2.1. 令 $X_1, \dots, X_n$ 是来自概率函数 $f(x; \theta)$ 的随机样本, 其中 $\theta = (\theta_1, \dots, \theta_k)$, 假设联合密度函数满足一些正则条件, 参数空间 Θ 是 k 维的, 考虑如下的统计假设:

$$H_0: \theta_1 = \theta_1^0, \dots, \theta_r = \theta_r^0, \theta_{r+1} \dots, \theta_k$$

其中 $\theta_1^0, \dots, \theta_r^0$ 已知, $\theta_{r+1}, \dots, \theta_k$ 未知, 则在 H_0 成立的条件下, 当样本量 $n \rightarrow \infty$, 似然比检验统计量 $-2 \log \Lambda_n$ 的渐进分布是自由度为 r 的卡方分布, 即 $-2 \log \Lambda_n \xrightarrow{H_0} \chi^2(r)$.

渐近卡方分布的自由度可以由下面两种方式确定:

- (1) 原假设 H_0 中确定参数的个数
- (2) 参数空间 Θ 的维数减去 Θ_0 的维数, 即 $r = \dim(\Theta) - \dim(\Theta_0)$.

最后我们来看一致最优势检验,他是这样定义的:

定义 3.2.4. 关于 $H_0: \theta \in \Theta_0$ vs $H_1: \theta \in \Theta_1$ 的检验 T^* 被定义为检验水平为 α 的一致最优势检验 (UMPT) 当且仅当

1. $\sup_{\theta \in \Theta_0} \pi_{T^*}(\theta) = \alpha$
2. 对任意一个检验水平小于或等于 α 的检验 T , 对所有的 $\theta \in \Theta - \Theta_0$, 有 $\pi_{T^*}(\theta) \geq \pi_T(\theta)$.

在讲解如何求解 UMPT 之前, 我们先引入一个单调似然比的概念:

定义 3.2.5. 设 $X_1, \dots, X_n$ 是来自密度族 $\{f(x; \theta); \theta \in \Theta, \Theta \text{ 是区间}\}$ 的样本, $L(\theta; x_1, \dots, x_n)$ 是其似然函数, 如果存在统计量 $T = T(X_1, \dots, X_n)$, 使得对 $\theta' < \theta''$, 似然比

$$\frac{L(\theta'; x_1, \dots, x_n)}{L(\theta''; x_1, \dots, x_n)}$$

是 $T(x_1, \dots, x_n)$ 的非增函数 (或非降函数), 则称该密度组关于统计量 $T(X_1, \dots, X_n)$ 有单调似然比。

例 3.2.4. 证明密度族:

$$\{f(x; \theta) : \theta \in \Theta\} = \{\theta e^{-\theta x} I_{(0, \infty)}(x) : \theta > 0\}$$

有单调似然比

基于单调似然比, 我们有这样的判断方法:

定理 3.2.2. 令 $X_1, \dots, X_n$ 是来自 $\{f(x; \theta), \theta \in \Theta\}$ 的随机样本, 其中 Θ 是区间, 假设

$$f(x; \theta) = a(\theta)b(x) \exp[c(\theta)d(x)]$$

$$\text{令 } T(x_1, \dots, x_n) = \sum_{i=1}^n d(x_i)$$

1. 如果 $c(\theta)$ 是 θ 的单调增函数, 且存在 k^* , 满足

$$P_{\theta_0}(T(X_1, \dots, X_n) > k^*) = \alpha$$

则具有拒绝域 $C^* = \{(x_1, \dots, x_n) : T(x_1, \dots, x_n) > k^*\}$ 的检验 T^* 是假设检验 $H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$ 或 $H_0: \theta = \theta_0$ vs $H_1: \theta > \theta_0$ 的检验水平为 α 的一致最优势检验。

2. 如果 $c(\theta)$ 是 θ 的单调减函数, 且存在 k^* , 满足

$$P_{\theta_0}(T(X_1, \dots, X_n) < k^*) = \alpha$$

则具有拒绝域 $C^* = \{(x_1, \dots, x_n) : T(x_1, \dots, x_n) < k^*\}$ 的检验 T^* 是假设检验 $H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$ 或 $H_0: \theta = \theta_0$ vs $H_1: \theta > \theta_0$ 的检验水平为 α 的一致最优势检验。

例 3.2.5. 令 $X_1, \dots, X_n$ 是来自 $f(x; \theta) = \theta e^{-\theta x}$ 的随机样本, 其中 $\theta > 0$, 找假设检验 $H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$ 的假设检验水平为 α 的 UMPT。

我们将上面的方法推广至一般的情形:

定理 3.2.3. 令 $X_1, \dots, X_n$ 是来自 $\{f(x; \theta), \theta \in \Theta\}$ 的随机样本, 其中 Θ 是区间, 假设密度族 $\{f(x; \theta) : \theta \in \Theta\}$ 关于 $T(X_1, \dots, X_n)$ 有单调似然比

1. 如果单调似然比是关于 $T(X_1, \dots, X_n)$ 非减函数, 如果 k^* 使得

$$P_{\theta_0}[T(X_1, \dots, X_n) < k^*] = \alpha$$

则对应于拒绝域 $C^* = \{(x_1, \dots, x_n) : T(x_1, \dots, x_n) < k^*\}$ 的检验是假设检验 $H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$ 的检验水平为 α 的一致最优势检验。

2. 如果单调似然比是关于 $T(X_1, \dots, X_n)$ 非增函数, 如果 k^* 使得

$$P_{\theta_0}[T(X_1, \dots, X_n) > k^*] = \alpha$$

则对应于拒绝域 $C^* = \{(x_1, \dots, x_n) : T(x_1, \dots, x_n) > k^*\}$ 的检验是假设检验 $H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$ 的检验水平为 α 的一致最优势检验。

例 3.2.6. 令 $X_1, \dots, X_n$ 是来自 $f(x; \lambda) = \frac{\lambda^x}{x!} e^{-\lambda}$ 的随机样本, 其中 $\lambda > 0$, $x = 0, 1, \dots$, 找假设检验 $H_0: \lambda \leq \lambda_0$ vs $\lambda > \lambda_0$ 的检验水平为 α 的 UMPT。

例 3.2.7. 令 $X_1, \dots, X_n$ 是来自 $f(x; \theta) = \frac{1}{\theta} I_{(0, \theta)}(x)$ 的随机样本, 其中 $\theta > 0$, 找假设检验 $H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$ 的检验水平为 α 的 UMPT。

在本节的最后我们介绍无偏检验:

定义 3.2.6. 对于原假设为 $H_0: \theta \in \Theta_0$, 备择假设 $H_1: \theta \in \Theta_1$ 的检验 T 被称为无偏检验当且仅当

$$\sup_{\theta \in \Theta_0} \pi_T(\theta) \leq \inf_{\theta \in \Theta_1} \pi_T(\theta)$$

3.3 正态总体参数假设检验

在本节首先我们考虑对正态分布的参数 μ, σ^2 的假设检验, 我们的方法是这样的:

1. 根据实际问题提出原假设或备择假设
2. 找一个检验统计量, 然后给出拒绝域
3. 根据检验水平, 利用检验统计量的分布计算临界值

4. 根据样本的取值，计算检验统计量的取值，最后下结论

这里我们给出这几种检验的类型：

Table: 正态总体均值的检验

	H_0	H_1	检验统计量	拒绝域
σ^2 已知	$\mu \leq \mu_0$ $\mu \geq \mu_0$ $\mu = \mu_0$	$\mu > \mu_0$ $\mu < \mu_0$ $\mu \neq \mu_0$	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$z > z_{1-\alpha}$ $z < z_\alpha$ $ z > z_{1-\alpha/2}$
σ^2 未知	$\mu \leq \mu_0$ $\mu \geq \mu_0$ $\mu = \mu_0$	$\mu > \mu_0$ $\mu < \mu_0$ $\mu \neq \mu_0$	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$	$t > t_{1-\alpha}(n-1)$ $t < t_\alpha(n-1)$ $ t > t_{1-\alpha/2}(n-1)$

Table: 正态总体方差参数的检验

	H_0	H_1	检验统计量	拒绝域
μ 已知	$\sigma^2 \leq \sigma_0^2$ $\sigma^2 \geq \sigma_0^2$ $\sigma^2 = \sigma_0^2$	$\sigma^2 > \sigma_0^2$ $\sigma^2 < \sigma_0^2$ $\sigma^2 \neq \sigma_0^2$	$Q = \frac{\sum_{i=1}^n (X_i - \mu_0)^2}{\sigma_0^2}$	$q > \chi_{1-\alpha}^2(n)$ $q < \chi_\alpha^2(n)$ $q < \chi_{\frac{\alpha}{2}}^2(n)$ or $q > \chi_{1-\frac{\alpha}{2}}^2(n)$
μ 未知	$\sigma^2 \leq \sigma_0^2$ $\sigma^2 \geq \sigma_0^2$ $\sigma^2 = \sigma_0^2$	$\sigma^2 > \sigma_0^2$ $\sigma^2 < \sigma_0^2$ $\sigma^2 \neq \sigma_0^2$	$V = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma_0^2}$	$v > \chi_{1-\alpha}^2(n-1)$ $v < \chi_\alpha^2(n-1)$ $v < \chi_{\frac{\alpha}{2}}^2(n-1)$ or $v > \chi_{1-\frac{\alpha}{2}}^2(n-1)$

Table: Hypothesis tests on two variances

	H_0	H_1	检验统计量	拒绝域
μ_1 和 μ_2 已知	$\sigma_1^2 \leq \sigma_2^2$ $\sigma_1^2 \geq \sigma_2^2$ $\sigma_1^2 = \sigma_2^2$	$\sigma_1^2 > \sigma_2^2$ $\sigma_1^2 < \sigma_2^2$ $\sigma_1^2 \neq \sigma_2^2$	$F = \frac{\sum_{i=1}^n (x_i - \mu_1)^2 / n}{\sum_{i=1}^m (y_i - \mu_2)^2 / m}$	$F > F_{1-\alpha}(n, m)$ $F < F_\alpha(n, m)$ $\{F > F_{1-\alpha/2}(n, m)$ or $F < F_{\alpha/2}(n, m)\}$
μ_1 和 μ_2 未知	$\sigma_1^2 \leq \sigma_2^2$ $\sigma_1^2 \geq \sigma_2^2$ $\sigma_1^2 = \sigma_2^2$	$\sigma_1^2 > \sigma_2^2$ $\sigma_1^2 < \sigma_2^2$ $\sigma_1^2 \neq \sigma_2^2$	$\tilde{F} = \frac{S_x^2}{S_y^2}$	$\tilde{F} > F_{1-\alpha}(n, m)$ $\tilde{F} < F_\alpha(n-1, m-1)$ $\{\tilde{F} > F_{1-\alpha/2}(n-1, m-1)$ or $\tilde{F} < F_{\alpha/2}(n-1, m-1)\}$

2. 多个均值的相等性：检验假设为：

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k \quad \text{vs} \quad H_1 : \exists i, j, j \neq i \text{ s.t. } \mu_i \neq \mu_j, \quad i, j \in \{1, 2, \cdots, k\}$$

与第一种情况的算法相同, 我们得到拒绝域为 $C = \{r > F_{1-\alpha}(k-1, n-k)\}$, 其中 $F_{1-\alpha}(k-1, n-k)$ 是 $F(k-1, n-k)$ 的 $1-\alpha$ 分位数, 并且

$$r = \frac{\sum_{j=1}^k n_j (\bar{X}_j - \bar{X})^2 / (k-1)}{\sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ji} - \bar{X}_j)^2 / (n-k)}$$

3. 多个方差的相等性：我们的检验假设如下：

$$H_0 : \sigma_1^2 = \sigma_2^2 = \cdots = \sigma_k^2 \quad \text{vs} \quad H_1 : \exists i, j, j \neq i \text{ s.t. } \sigma_i^2 \neq \sigma_j^2, \quad i, j \in \{1, \cdots, k\}$$

设其检验的水平为 α , 则拒绝域为

$$C = \{-2 \log \lambda > \chi_{1-\alpha}^2(k-1)\}$$

其中

$$\lambda = \frac{\prod_{j=1}^k (\hat{\sigma}_j^2)^{n_j/2}}{(\sum n_j \hat{\sigma}_j^2) / \sum n_j} \Sigma^{n_j/2}, \quad \hat{\sigma}_j^2 = \frac{1}{n_j} \sum_{i=1}^{n_j} (x_{ji} - \bar{x}_j)^2$$

3.4 卡方检验

本节我们考虑的问题是如下假设检验问题：

原假设： $H_0 : p_1^0, \cdots, p_k^0$, 其中 $p_j^0 \in (0, 1)$, $j = 1, \cdots, k$, 已知 $\sum_{j=1}^k p_j^0 = 1$, 备择假设： H_1 至少存在一个 j , $p_j \neq p_j^0, j = 1, \cdots, k$.

这里我们对问题进行多次实验, 我们独立重复的进行 n 次试验, 每次记为 $(X_{i1}, \cdots, X_{ik})$, 得到广义似然比为

$$\lambda = \prod_{j=1}^k \left(\frac{np_j^0}{n_j} \right)^{n_j}$$

其中 np_j^0 是期望出现的次数, n_j 是试验中实际出现的次数, 设检验水平为 α , 则其对应的拒绝域为

$$C = \{-2 \log \lambda > \chi_{1-\alpha}^2(k-1)\}, \quad \text{其中} \quad -2 \log \lambda = -2 \sum_{j=1}^k n_j \log(np_j^0/n_j)$$

这里我们令 $N_j = \sum_{i=1}^n X_{ij}$, 表示 n 次试验中出现 j 的次数, 则我们下面讨论 $Q_{k-1}^0 = \sum_{j=1}^k \frac{(N_j - np_j^0)^2}{np_j^0}$, 当 H_0 正确时, 统计量 Q_{k-1}^0 倾向于比较小, 当 H_0 错误时, 统计量 Q_{k-1}^0 倾向于比较大, 故拒绝域为 $\{Q_{k-1}^0 > q\}$, 其中 q 是临界值, 由此我们给出这样的定理：

定理 3.4.1. 随机试验的可能结果可以表示为 k 个互不相交的集合, 即 $A_1, \dots, A_k$, 令 $p_j = P(A_j)$, $j = 1, \dots, k$, 在 n 独立的重复实验中, 令 N_j 表示出现 A_j 的次数, 其中 $j = 1, \dots, k$, 因此 $\sum_{j=1}^k N_j = n$, 当 $n \rightarrow \infty$ 时, 则

$$Q_{k-1} = \sum_{j=1}^k \frac{(N_j - np_j)^2}{np_j}$$

的渐进分布是自由度为 $k-1$ 的卡方分布。

但是, 类 j 出现的概率 p_j 通常是未知的, 且依赖于分布中的未知参数, 此时我们应使用下面的定理:

定理 3.4.2. 设某随机试验的可能结果分为 k 个互斥的子集: $A_1, \dots, A_k$, 定义 $p_j = P(A_j)$, $j = 1, \dots, k$, 假设 p_j 依赖于 r 个未知参数 $\theta_1, \dots, \theta_r$, 因此 $p_j = p_j(\theta_1, \dots, \theta_r)$, $j = 1, \dots, k$, $\sum_{j=1}^k N_j = n$, 令 $\hat{\theta}_1, \dots, \hat{\theta}_r$ 是参数 $\theta_1, \dots, \theta_r$ 基于 $N_1, \dots, N_k$ 的极大似然估计, 在某些正则条件下,

$$Q' = \sum_{j=1}^k \frac{(N_j - n\hat{p}_j)^2}{n\hat{p}_j}$$

的渐进分布为自由度为 $k-1-r$ 的卡方分布, 其中 $\hat{p}_j = p_j(\hat{\theta}_1, \dots, \hat{\theta}_r)$, $j = 1, \dots, k$.

例 3.4.1. 假设检验观测样本 $x_1, \dots, x_n$ 是否来自某个正态分布 $\mathcal{N}(\mu, \sigma^2)$.

下面我们考虑两个多项总体是否相同的假设检验, 两个多项总体分别为

$$(N_1, \dots, N_k) \sim \text{Multi}(p_{11}, p_{12}, \dots, p_{1k})$$

$$(N'_1, \dots, N'_k) \sim \text{Multi}(p_{21}, p_{22}, \dots, p_{2k})$$

检验的原假设 $H_0: p_{1j} = p_{2j}$, $j = 1, \dots, k$, 此时若有 H_0 成立, 我们有

$$Q = \sum_{i=1}^2 \sum_{j=1}^k \frac{(N_{ij} - n_i p_j)^2}{n_i p_j} \rightsquigarrow \chi^2(2k-2)$$

如果 p_j 用其极大似然估计代替, 则

$$Q' = \sum_{i=1}^2 \sum_{j=1}^k \frac{[N_{ij} - n_i(N_{ij} + N_{2j})/(n_1 + n_2)]^2}{n_i(N_{1j} + N_{2j})/(n_1 + n_2)}$$

Q' 的极限分布为自由度为 $k-1$ 的卡方分布。

卡方检验的最后一个问题就是列联表的独立性检验, 首先是 2×2 列联表, 我们使用广义似然比方法, 得到 Pearson χ^2 统计量

$$Q = \sum_{i=1}^2 \sum_{j=1}^2 \frac{(nn_{ij} - n_{i \cdot} n_{\cdot j})^2}{nn_{i \cdot} n_{\cdot j}} \rightsquigarrow \chi^2(1)$$

拒绝域为 $C = \{Q > \chi^2_{1-\alpha}(1)\}$.